

# 成本有效的通信：一种基于拍卖的语言体交互方法

*Cost-Effective Communication: An Auction-based Method for Language Agent Interaction*

Yijia Fan, Jusheng Zhang, Kaitong Cai, Jing Yang, Chengpei Tang, Jian Wang, Keze Wang

中山大学 / Snap Inc. / 广东省大数据分析与处理重点实验室

说明：本译稿根据原始 PDF 整理为中文版本，文中图 1-图 3 按原文逐一保留；参考文献为便于核对保留英文原文。

## 摘要

基于大语言模型（LLM）的多智能体系统（MAS）经常受到“人人都能说”的低效通信方式影响，导致 token 成本呈指数级增长，同时信噪比偏低，阻碍了其实际部署。本文挑战“通信越多越好”这一常见假设，认为问题的核心并不在于流量不足，而在于缺少对资源的理性管理。作者指出，所谓“免费”通信忽视了稀缺性原则，天然会滋生低效和不必要的开销。为此，论文提出动态拍卖式语言智能体框架 DALA（Dynamic Auction-based Language Agent），将通信带宽视为一种稀缺且可交易的资源。在该框架中，智能体之间的交流被建模为集中式拍卖，智能体依据消息的预测价值密度来竞争发言权。因此，DALA 会从机制上鼓励智能体输出简洁而信息密度高的消息，同时过滤低价值通信。大量实验表明，这一经济学驱动的框架在七个具有挑战性的推理基准上取得了新的最优结果，例如 MMLU 达到 84.32%，HumanEval 的 pass@1 达到 91.21%。更重要的是，它在 GSM8K 上只消耗约 625 万 token，仅为现有最优方法开销的一小部分。进一步分析显示，DALA 还能诱导出“策略性沉默”这一涌现能力，使智能体在资源约束下能够动态地在“详细表达”和“保持沉默”之间切换。

## 1 引言

大语言模型研究正在从单智能体求解器快速转向更复杂的多智能体系统。与单个模型相比，多智能体系统有望解决超出单一模型能力边界的问题。在复杂推理与软件开发等场景中，这种协作范式已经展现出初步成功：多个智能体可以汇聚分布式知识，并在迭代对话中不断修正答案。

然而，现有进展往往依赖“自由放任式”的通信协议，即允许智能体以很低代价广播信息。这样的架构会导致 token 消耗急剧膨胀，并使大量低价值、冗长的交流淹没有用信号。诸如 PHP 和 DyLAN 等方法虽然提升了性能，却普遍忽视了通信的资源成本，带来了较高的运行开销和较低的信噪比。例如在 GSM8K 上，这类方法往往要消耗数千万 token，难以支持高效部署。

与其继续只关注提升单个智能体能力或做简单的信息剪枝，作者认为，通信协议本身——也就是“谁应该在什么时候、以何种方式进行交流”——同样值得被系统性设计。

本文提出一个核心观点：多智能体系统的瓶颈并不是交流不够，而是缺乏预算管理意义上的资源理性。若把通信带宽视为一种稀缺的公共资源，并迫使智能体在模拟市场中行动，系统就可能自组织地优先选择简洁且高价值的信息交换。换言之，“免费”通信由于无视稀缺性而天然低效；相反，恰当的激励机制有望催生理性的涌现智能，并在性能与效率之间取得平衡。

基于这一假设，论文提出 DALA。该框架将智能体间通信重新定义为集中式拍卖过程，智能体必须“付费发言”，整体则通过 MAPPO 进行训练。每个智能体根据潜在消息的预测价值密度进行出价，从机制上激励其输出简洁且信息量更高的内容，以赢得通信机会。这样一来，系统就会自动压制低价值闲聊，形成更审慎、更高效的对话环境。




图 1 DALA 总体框架示意图。Actor 网络生成候选消息，Critic 网络根据效用与成本计算其价值密度  $\rho_i$ ；该密度作为预算约束下 VCG 拍卖中的出价，用于分配发言权。整个 actor-critic 系统使用 MAPPO 训练，以同时最大化任务成功与拍卖成本约束下的收益。

## 本文贡献

- 将“资源理性”引入多智能体系统研究，指出真正关键的是通信 token 的稀缺管理，而不是盲目增加流量。
- 提出 DALA：一种基于动态拍卖机制的语言智能体框架，要求智能体评估消息的价值密度并为发言权出价。
- 实验表明，DALA 不仅以远低于现有方法的 token 成本取得新的最优性能，还能培养出“策略性沉默”这一关键涌现能力。

## 2 相关工作

多智能体通信的演化。多智能体系统中的高效通信并不是新问题，但在以 token 为代价的大模型时代，这一挑战被显著放大。早期 MAS 研究在言语行为理论的影响下发展出标准化的智能体通信语言（ACL），以保证语义清晰；随后，合同网协议（CNP）又为任务分配提供了务实的协商框架。事实上，早期研究者已经意识到，如果不约束通信开销，系统很容易陷入高昂的交互负担。进入深度强化学习时代后，研究重点从固定协议转向学习型的涌现通信策略。然而，自由放任式通信经常引入噪声并阻碍协作，这催生了围绕拓扑剪枝、门控剪枝和表示学习等方向的通信效率研究。尽管这些方法有效，它们通常缺少一个统一且有原则的框架，用来显式衡量“一条消息的收益是否值得它的代价”。

经济机制与信息瓶颈原理。当通信带宽是一种稀缺资源时，资源分配自然就成为经济学问题。拍卖理论为此提供了严格工具，其中 Vickrey-Clarke-Groves (VCG) 机制尤为重要。VCG 具有激励相容性，鼓励真实出价，并以最大化社会福利为目标，使资源更可能分配给真正最重视它的参与者。该机制已在无线频谱分配、序列拍卖、Bandit 系统等问题中得到验证。本文把这一思想用于多智能体通信，并引入“价值密度”（ $\rho = \text{value}/\text{cost}$ ）的概念作为出价基础。它与信息瓶颈（IB）原则高度契合：DALA 的目标是让智能体将私有知识压缩成单位 token 价值更高的消息，以最低成本为团队任务带来最大收益。

基于 LLM 的多智能体通信效率。近期建立在大语言模型之上的 MAS 在复杂推理和软件开发中取得了显著进展，但其性能通常建立在自由放任式通信所带来的巨额 token 消耗之上。尽管已有一些方法开始关注这一问题，例如 AgentPrune-R 会基于随机图拓扑裁剪通信链路，但这些裁剪决策缺乏真正的价值驱动依据。DALA 将多智能体强化学习与 VCG 拍卖机制结合起来，构造出一个“通信市场”，迫使智能体为发言机会出价，从而培养出一种以“策略性沉默”为特征的资源理性，在性能与成本之间取得平衡。

## 3 方法

### 3.1 问题表述

DALA 的学习目标是找到最优的联合策略参数  $\Theta^* = \{\theta_1^*, \dots, \theta_N^*\}$ ，在预算约束下最大化轨迹回报的期望。文中预算约束写为：

$$\begin{aligned} \Theta^* &= \arg \max_{\Theta} \mathbb{E}_{\tau \sim \pi_{\Theta}} [R(\tau)] \\ \text{s. t. } \mathbb{E}_{\tau \sim \pi_{\Theta}} \left[ \sum_{t=1}^T \sum_{a_j \in W_t} L(m_j^{(t)}) \right] &\leq B \end{aligned}$$

需要注意的是，上式中的预算约束属于“期望意义上的软约束”；而拍卖机制在每一轮内部使用的是硬预算约束，它在实际求解中起到了落实软约束优化目标的作用。

### 3.2 基于价值的竞价机制

DALA 设计了一套有原则的竞价机制，让智能体利用学习得到的价值网络评估消息的边际效用，并据此出价。该过程由 Actor Network 驱动的提示标注机制启动：当系统收到问题后，会先对输入进行分词，再由 Actor Network 为每个 token 输出一个重要性权重，从而评估输入中每个词的显著性。随后，系统将原始词和对应权重交织成新的标注式提示，例如把 “Explain the Pythagorean theorem” 转换成 “Explain [0.3] the [0.2] Pythagorean [0.9] theorem [0.8]”。这个带有重要性提示的输入会进一步送入语言模型，引导其更加关注关键部分，从而生成更聚焦、更相关的候选消息。

为了让智能体学会近似理性的竞价策略，作者为每个智能体  $a_i$  定义了消息条件价值函数  $V_{\theta_i}^V$ 。该函数用于预测：在当前观察  $o_i^{(t)}$  下，如果生成并广播某一候选消息  $m$ ，团队的期望累计回报会是多少。其形式为：

$$v_i(m, o_i^{(t)}) = g^V(\phi_M(m) \oplus \phi_O(o_i^{(t)}); \theta_i^V)$$

$$\rho_i(m, o_i^{(t)}) = \frac{v_i(m, o_i^{(t)}) - \bar{v}_t}{\sigma_{v_t} + \varepsilon} \cdot \frac{1}{L(m)}$$

$$b_i^{(t)} = \max(0, \rho_i(m_i^{(t)}, o_i^{(t)}))$$

其中， $\phi_M$  和  $\phi_O$  分别是消息编码器与观察编码器， $\oplus$  表示多模态融合操作（例如注意力机制）， $g^V$  为多层感知机头。 $v_i$  本质上是一个与动作条件相关的价值，类似于 Q 值。作者进一步引入价值密度  $\rho_i$ ，把消息的绝对价值与其长度成本结合起来；其中  $\bar{v}_t$  与  $\sigma_{v_t}$  分别表示当前拍卖轮次中所有候选消息价值的均值与标准差，用于把价值动态规范化为 Z-score， $\varepsilon$  为数值稳定项。

智能体的出价函数  $b_i^{(t)}$  直接由价值密度决定，因此只有那些经规范化后仍具有正向边际效用的消息，才有资格进入拍卖。基于价值密度的大小，DALA 还设计了四级输出策略：当  $\rho_i \geq \tau_{full}$  时生成完整详细消息（Full）；当  $\tau_{summary} \leq \rho_i < \tau_{full}$  时生成摘要（Summary）；当  $\tau_{keywords} \leq \rho_i < \tau_{summary}$  时只输出关键词（Keywords）；若  $\rho_i < \tau_{keywords}$ ，则保持沉默（Silence）。

这些阈值把正值区间进一步划分成不同层级，使系统能够根据消息价值自动控制表达粒度：价值越高，表达越完整；价值不足时则压缩为摘要、关键词，乃至不发言。论文给出的示例表

明，同一问题在较低价值密度下会被压缩成“关键词回答”，从而把有限的 token 预算留给更有价值的信息。

### 3.3 DALA 的组合拍卖机制

为了让多名智能体能够在同一轮中同时通信，论文把单赢家拍卖扩展为组合拍卖，并采用 VCG 支付规则。不再只选择一个赢家，而是寻找一个“赢家集合”  $W_t$ ，使得在不超过当前轮预算的情况下，该集合内消息的总价值最大。这一问题被称为赢家确定问题（Winner Determination Problem, WDP），形式上可写为一个经典的 0/1 背包问题：

$$W_t = \arg \max_{S \subseteq B_{\text{valid}}} \sum_{a_j \in S} b_j^{(t)}$$

$$\text{s. t. } \sum_{a_j \in S} L(m_j^{(t)}) \leq B_{\text{max}}^{(t)}$$

虽然从一般意义上看 WDP 是 NP-hard 的，但对于中等规模的智能体群体，仍可以通过动态规划高效求解。

在组合拍卖中，VCG 机制保证“真实出价”仍是每个智能体的占优策略。对于任意赢家，其支付定义为：在没有它参与时，系统能够达到的最优总价值，减去它存在时其他赢家实际获得的价值。也就是说，支付反映的是该智能体对其他人造成的“社会成本”或“外部性”。若某个智能体没有中标，则其支付为 0。

$$p_j^{(t)} = \left( \max_{S \subseteq B_{\text{valid}} \setminus \{j\}} \sum_{a_k \in S} b_k^{(t)} \right) - \left( \sum_{a_k \in W_t \setminus \{j\}} b_k^{(t)} \right)$$

在预算管理方面，DALA 使用分层控制：首先设定整个 episode 的总预算  $B_{\text{episode}}$ ；然后根据已经消耗的通信成本动态计算轮级预算  $B_{\text{round}}^{(t)}$ ；最后再用瞬时硬上限  $B_{\text{max}}^{(t)} = \min(B_{\text{round}}^{(t)}, B_{\text{hard}})$  控制每一轮可用资源。这里赢家“支付”的并不是货币，而是其消息长度所占用的通信预算。当预算趋紧或耗尽时，系统会自动压缩消息、强制沉默，并向智能体发出预算告警，引导其生成更短的内容。

#### 算法 1: DALA 组合拍卖机制（译）

1. 预算过滤：构造有效候选集合  $B_{\text{valid}} = \{(m_i^{(t)}, b_i^{(t)}) \mid L(m_i^{(t)}) \leq B_{\text{max}}^{(t)}\}$ 。
2. 赢家确定：在  $B_{\text{valid}}$  上求解 WDP，得到赢家集合  $W_t$ 。
3. 初始化所有智能体的支付  $p_i^{(t)} = 0$ ，并计算赢家集合总价值  $V(W_t)$ 。
4. 对每个赢家  $a_j$ ：从候选集合中移除  $a_j$ ，重新求解一次 WDP，得到假设没有  $a_j$  时的最优赢家集合  $W_t^j$ 。



5. 计算无  $a_j$  时的最优价值  $V(W_t \setminus \{j\})$ ，以及实际结果中“除  $a_j$  外其他赢家”的价值  $V(W_t \setminus \{j\})$ 。
6. 根据 VCG 规则设定支付： $p_j^{(t)} = V(W_t \setminus \{j\}) - V(W_t \setminus \{j\})$ 。
7. 实际预算开销  $C^{(t)}$  等于赢家集合中所有消息长度之和。
8. 输出赢家集合、其消息、总成本以及各自支付。

### 3.4 多智能体策略优化与奖励设计

DALA 的动态交互和奖励结构共同构成了多智能体强化学习环境。由于奖励稀疏且具有团队属性，作者采用多智能体近端策略优化（MAPPO）来学习策略参数。对每个智能体，定义策略比率；随后使用带裁剪的策略目标、价值函数损失，以及熵正则项共同构成最终优化目标。

论文在新的组合拍卖语境下重新设计了即时奖励函数：

$$r_i^{(t)} = \alpha \cdot \Delta task^{(t)} - \beta \cdot p_i^{(t)} \cdot I[a_i \in W_t]$$

其中， $\Delta task^{(t)}$  表示团队联合行动对任务进度的边际贡献，例如  $G_t - G_{t-1}$ ；若智能体进入赢家集合，则其还需承担由 VCG 支付给出的个体通信成本。 $\alpha$  和  $\beta$  用于平衡任务收益与通信成本。

消息价值学习部分保持不变：消息条件价值网络通过最小化 TD 误差来学习对特定消息的预期回报估计，从而为出价提供基础，其目标可写为：

$$L_{\text{value}} = \mathbb{E}[(v_i(m_i^{(t)}, o_i^{(t)}) - R_i^{(t)})^2]$$

另一方面，出价策略则通过更新后的奖励函数学会：一条消息不仅要“单独看起来有用”，还要能够以合理成本进入一个高价值的赢家组合。

奖励反馈还会引导智能体形成更有利的“联盟”。如果某个智能体所在的赢家集合带来了较高的正向任务增益，整个团队就会得到正向奖励，从而强化这类组合；反之，如果该组合带来的任务贡献很低甚至为负，则团队奖励会惩罚这类低效组合。没有中标的智能体不会支付通信成本，只会接收到团队层面的任务奖励，这会反过来教会它们：当自己的消息不太可能属于高价值组合时，最好保持沉默。经过多轮 MAPPO 优化后，智能体会逐步内化出更复杂的理性逻辑——“只有当我的信息能够成为高价值联盟的一部分时，它才值得被竞价”。

## 4 实验

### 4.1 基线方法

为全面评估 DALA，作者将其与一系列强基线进行比较。单智能体方法包括 Vanilla prompting、Chain-of-Thought (CoT)、Complex CoT 和 Self-Consistency (SC)；多智

能体方法包括 PHP、LLM-Debate、DyLAN，以及基于随机图拓扑做通信剪枝的 AgentPrune-R。

4.2 数据集

实验覆盖三个核心推理领域中的七个基准：通用推理使用 MMLU；数学推理使用 GSM8K、MultiArith、SVAMP、AQuA 和更具挑战性的 MATH-500；代码生成使用 HumanEval 评估函数级编程能力。对于没有标准训练集的基准，作者沿用类似 AgentPrune-R 的数据优化范式：从每个基准中抽取 2% 数据作为策略优化集，用来训练基于价值密度的出价策略；当该策略经 MAPPO 优化并固定后，再在剩余 98% 未见数据上做最终评估。

4.3 实验设置

为公平比较各类通信框架，所有实验都使用 gpt-4-1106-preview 作为底层大模型。不同任务下，DALA 设置不同的总预算来控制通信成本。对每个样本，作者把关键的数学公式、上下文事实或必要代码片段分散给不同智能体，确保没有任何单个智能体能够独立解题，从而使“高效通信”成为成功的必要条件。所有实验均在 NVIDIA A100 80GB 上完成。

4.4 性能与成本效益

表 1 显示，DALA 在七个基准上都建立了新的最优结果。在 MMLU 上，其准确率达到 84.32%；在 GSM8K 上达到 96.18%，比此前表现最好的 AgentPrune-R 再提升 1.35 个百分点；在 HumanEval 和 MATH-500 上也分别取得 91.21% 和 83.42% 的最佳成绩。这说明 DALA 能够在不同任务域内稳定地促进更高质量的协作，并直接转化为更高的最终求解准确率。

除了性能优势外，DALA 在经济效率方面也十分突出。图 2 及表 2 表明，它长期处于“高准确率、低成本”的象限：在 MMLU 上仅消耗约  $1.81 \times 10^5$  个 token，显著低于 PHP 等方法；在 GSM8K 上，其约  $6.25 \times 10^6$  的 token 使用量也远低于 DyLAN 等高成本方案。论文认为，这种优势正来自“付费发言”的价值密度拍卖机制，它从系统内部抑制了低价值、冗长的信息交换，使 DALA 更具可扩展性与部署实用性。

表 1 七个推理基准上的总体性能对比（除 HumanEval 外均为准确率 %，HumanEval 为 pass@1 %）

| 方法      | MMLU             | MultiArith       | GSM8K         | SVAMP         | AQuA             | HumanEval        | MATH-500      |
|---------|------------------|------------------|---------------|---------------|------------------|------------------|---------------|
| 单智能体方法  |                  |                  |               |               |                  |                  |               |
| Vanilla | 82.14            | 93.15            | 85.40         | 87.18         | 70.34            | 71.68            | 73.72         |
| CoT     | 82.65<br>(+0.51) | 94.79<br>(+1.64) | 87.17 (+1.77) | 88.32 (+1.14) | 73.91<br>(+3.57) | 75.52<br>(+3.84) | 75.18 (+1.46) |

|                  |                          |                          |                           |                          |                           |                           |                          |
|------------------|--------------------------|--------------------------|---------------------------|--------------------------|---------------------------|---------------------------|--------------------------|
| ComplexCo<br>T   | 83.78<br>(+1.64)         | 95.86<br>(+2.71)         | 87.62<br>(+2.22)          | 90.17<br>(+2.99)         | 77.58<br>(+7.24)          | 74.94<br>(+3.26)          | 76.85<br>(+3.13)         |
| SC               | 82.66<br>(+0.52)         | 96.88<br>(+3.73)         | 87.93<br>(+2.53)          | 88.69 (+1.51)            | 75.08<br>(+4.74)          | 77.30<br>(+5.62)          | 77.02<br>(+3.30)         |
| 多智能体方法           |                          |                          |                           |                          |                           |                           |                          |
| PHP              | 83.45 (+1.31)            | 96.41<br>(+3.26)         | 92.45<br>(+7.05)          | 90.62<br>(+3.44)         | 76.25<br>(+5.91)          | 82.96<br>(+11.28)         | 79.24<br>(+5.52)         |
| LLM-<br>Debate   | 83.69<br>(+1.55)         | 96.27<br>(+3.12)         | 90.23<br>(+4.83)          | 90.56<br>(+3.38)         | 77.52<br>(+7.18)          | 83.79<br>(+12.11)         | 80.15<br>(+6.43)         |
| DyLAN            | 80.16 (-1.98)            | 94.27 (+1.12)            | 88.16<br>(+2.76)          | 87.40<br>(+0.22)         | 74.16<br>(+3.82)          | 89.70<br>(+18.02)         | 81.66<br>(+7.94)         |
| AgentPrun<br>e-R | 83.94<br>(+1.80)         | 96.30<br>(+3.15)         | 95.83<br>(+10.43)         | 91.68<br>(+4.50)         | 78.60<br>(+8.26)          | 90.30<br>(+18.62)         | 82.81<br>(+9.09)         |
| DALA (本<br>文)    | <b>84.32<br/>(+2.18)</b> | <b>97.87<br/>(+4.72)</b> | <b>96.18<br/>(+10.78)</b> | <b>92.33<br/>(+5.15)</b> | <b>80.92<br/>(+10.58)</b> | <b>91.21<br/>(+19.53)</b> | <b>83.42<br/>(+9.70)</b> |

表 2 MMLU 与 GSM8K 上的性能—token 消耗汇总对比

| 方法           | MMLU 准确率 (%) | MMLU Token 消耗                        | GSM8K 准确率 (%) | GSM8K Token 消耗                       |
|--------------|--------------|--------------------------------------|---------------|--------------------------------------|
| DALA (本文)    | <b>84.3</b>  | <b><math>3.80 \times 10^5</math></b> | <b>96.2</b>   | <b><math>6.20 \times 10^6</math></b> |
| AgentPrune-R | 84.0         | $9.60 \times 10^5$                   | 95.8          | $7.50 \times 10^6$                   |
| LLM-Debate   | 83.7         | $1.50 \times 10^6$                   | 90.2          | $2.20 \times 10^7$                   |
| PHP          | 83.4         | $2.60 \times 10^6$                   | 92.5          | $2.60 \times 10^7$                   |
| DyLAN        | 80.2         | $1.20 \times 10^6$                   | 88.2          | $1.40 \times 10^7$                   |
| Vanilla      | 82.1         | $1.50 \times 10^5$                   | 85.4          | $3.50 \times 10^6$                   |






图 2 MMLU 上平均预测价值  $v_i$  的学习曲线。随着训练推进，价值网络迅速学会对关键信息赋予更高价值，同时降低对非关键信息的估值；两者差距在约第 160 个 epoch 后趋于稳定。

#### 4.5 涌现通信策略分析

为了验证“经济学驱动的通信市场能够培养复杂而高效的交流策略”这一核心假设，作者对智能体的涌现行为做了多角度分析。与仅看总准确率不同，这部分实验旨在揭示拍卖机制所塑造的细粒度决策过程。作者设置了两个总预算条件：一个是资源紧张情形  $1 \times 10^5$  token，另一个是资源宽松情形  $1 \times 10^6$  token。它们以 Vanilla（即 gpt-4-1106-preview）在 MMLU 上约  $1.5 \times 10^5$  token 的开销为参照。对于每种预算，统计四种关键通信策略——Full、Summary、Keywords 和 Silence——的频率。此外，论文还把 MMLU 中的信息操作性地区分为两类：关键性信息是推导正确答案所必需的推理步骤或事实；非关键性信息则包括冗余陈述、错误推理路径和闲聊式填充。这一分类由外部裁决模型 openai/o3-2025-04-16 完成。

图 2 所示的学习曲线表明，价值网络具备了对信息进行“估值”的能力，这是通信市场发挥作用的前提。起初，关键与非关键信息几乎被赋予相同的价值；随着训练进行，两条曲线迅速拉开，说明智能体逐渐学会了区分哪些信息值得付费传播。

这种内部估值能力进一步体现在图 3 的资源自适应策略中：在严格的  $1 \times 10^5$  token 预算下，智能体会显著减少 Full message 的使用，例如 STEM 领域仅 2.1%；同时更依赖被高度压缩的关键词输出，以及更高比例的策略性沉默。相反，在  $1 \times 10^6$  token 的宽松预算下，Full-text 成为主要策略，Humanities 甚至达到 48.7%，而沉默比例则降到很低。作者据此认为，DALA 中的智

能体并不是遵循静态策略，而是在根据资源状态和信息价值动态地调节表达方式，真正学会了“在预算紧张时少说，必要时不说，以及知道何时闭嘴”。




图 3 在两种总预算约束下，MMLU 不同领域中的通信策略分布对比：上图对应  $1 \times 10^6$  token，下图对应  $1 \times 10^5$  token。该图直观展示了智能体会随资源可用性动态调整交流策略。

4.6 模块消融

作者在 MMLU 与 GSM8K 上对 DALA 的关键组成模块进行了消融分析。实验分别移除：价值学习（Value Learning）、价值密度（Value Density）、分层输出（Tiered Content）、动态预算（Dynamic Budget）以及成本惩罚项（ $\beta=0$ ），以考察各模块对性能和通信效率的具体贡献。

表 3 DALA 模块消融结果（准确率 % / 平均 token 消耗）

| 变体                           | MMLU（准确率 %）  | GSM8K（准确率 %） | 平均 Token（ $\times 10^6$ ） |
|------------------------------|--------------|--------------|---------------------------|
| DALA（完整模型）                   | 84.32        | 96.18        | 3.22                      |
| 去除 Value Learning            | 75.77（↓8.55） | 86.35（↓9.83） | 4.13                      |
| 去除 Value Density             | 79.16（↓5.16） | 89.76（↓6.42） | 4.91                      |
| 去除 Tiered Content            | 79.83（↓4.49） | 90.95（↓5.23） | 4.49                      |
| 去除 Dynamic Budget            | 80.71（↓3.61） | 91.30（↓4.88） | 3.65                      |
| 去除 Cost Penalty（ $\beta=0$ ） | 77.48（↓6.84） | 88.27（↓7.91） | 6.23                      |

表 3 结果表明，一旦去掉任一关键模块，DALA 的性能都会明显下降。其中影响最大的是去除 Value Learning：MMLU 与 GSM8K 分别下降 8.55 和 9.83 个点，这直接验证了论文的核心判断——高效多智能体系统不仅需要通信，更需要对信息价值做智能评估。

类似地，去掉 Value Density 和 Cost Penalty 后，系统会变得更冗长、更低效，表明经济纪律对于抑制信息过载至关重要。与此同时，Tiered Content 与 Dynamic Budget 这类自适应机制也提供了重要帮助，使系统能够以更细粒度的方式管理信息—成本之间的权衡。

## 5 局限性与未来工作

尽管 DALA 表现强劲，但仍存在一些局限。首先，MAPPO 训练虽然有效，但在扩展到成千上万个智能体时计算成本会迅速增大，因此未来值得探索样本效率更高或可扩展性更强的多智能体强化学习范式。

其次，DALA 当前仍依赖一个中心化拍卖者。若能发展去中心化的拍卖机制，将有助于提升其在完全分布式场景中的鲁棒性和适用性。

最后，为了保证公平比较，本文使用的是单一同构智能体模型。未来的重要方向之一，是研究异构智能体系统，以及如何设计更加均衡的市场，使高能力智能体与低成本智能体能够共存而不引发“市场失灵”。

## 6 结论

本文提出 DALA，一个将通信重新解释为“市场驱动拍卖”的简单而有效的框架。通过激励智能体根据消息的价值密度进行出价，DALA 能够抑制低价值交换，并鼓励更审慎的通信。

实验表明，DALA 在七个推理基准上都取得了新的最优性能，同时所需 token 成本仅为许多现有方法的一小部分。更重要的是，它诱导出了“策略性沉默”这一涌现能力，使多智能体系统能够根据资源约束动态调整冗长程度。未来工作可以进一步探索更丰富的市场设计，或将这种经济学范式扩展到更多稀缺资源的管理。

## 致谢

本工作部分得到以下项目资助：国家自然科学基金（62276283）、中国气象局科技项目（CMA-JBGS202517）、广东省基础与应用基础研究基金（2023A1515012985）、粤港澳大湾区气象科技协同研究项目（GHMA2024Z04）、中山大学中央高校基本科研业务费（23hytd006），以及广东省高层次青年人才计划（RL2024-151-2-11）。

## 参考文献（原文保留）

以下参考文献为便于与原文逐项核对，保留英文条目。

2021. Evaluating Large Language Models Trained on Code. Chen, L.; Davis, J.; Hanin, B.; Bailis, P.; Stoica, I.; Zaharia, M.; and Zou, J. 2024. Are More LM Calls All You Need? Towards Scaling Laws of Compound AI Systems. Cobbe, K.; Kosaraju, V.; and Bavarian, M. et al. 2021. Training Verifiers to Solve Math Word Problems. arXiv preprint arXiv:2110.14168. Cramton, P.; Shoham, Y.; and Steinberg, R. 2006a. Combinatorial Auctions. The MIT Press. ISBN 0262033429. Cramton, P.; Shoham, Y.; and Steinberg, R. 2006b. Combinatorial Auctions. The MIT Press. ISBN 0262033429. Ding, Z.; Huang, T.; and Lu, Z. 2020.

Learning individually inferred communication for multi-agent cooperation. In NeurIPS, NIPS '20. Red Hook, NY, USA: Curran Associates Inc. ISBN 9781713829546. Du, Y.; Li, S.; Torralba, A.; Tenenbaum, J. B.; and Mordatch, I. 2024. Improving factuality and reasoning in language models through multiagent debate. ICML'24. JMLR.org. Fan, Y.; Zhang, J.; Cai, K.; Yang, J.; and Wang, K. 2025. CCG: Rare-Label Prediction via Neural SEM-Driven Causal Game. In Christodoulopoulos, C.; Chakraborty, T.; Rose, C.; and Peng, V., eds., Findings of the Association for Computational Linguistics: EMNLP 2025, 6243–6256. Suzhou, China: Association for Computational Linguistics. ISBN 979-8-89176-335-7. Fan, Y.; Zhang, J.; and Wang, K. 2025. Towards More Efficient Post-training via Fourier Domain Adapter Framework. In Christodoulopoulos, C.; Chakraborty, T.; Rose, C.; and Peng, V., eds., Findings of the Association for Computational Linguistics: EMNLP 2025, 6175–6193. Suzhou, China: Association for Computational Linguistics. ISBN 979-8-89176-335-7. Foerster, J. N.; Assael, Y. M.; de Freitas, N.; and Whiteson, S. 2016. Learning to communicate with Deep multi-agent reinforcement learning. In NeurIPS, NIPS'16, 2145–2153. Red Hook, NY, USA: Curran Associates Inc. ISBN 9781510838819. Fu, Y.; Peng, H.; Sabharwal, A.; Clark, P.; and Khot, T. 2023. Complexity-Based Prompting for Multi-Step Reasoning. arXiv:2210.00720. Gandhi, S.; Patwardhan, M.; Vig, L.; and Shroff, G. 2025. BudgetMLAgent: A Cost-Effective LLM Multi-Agent system for Automating Machine Learning Tasks. AIMS Systems '24. New York, NY, USA: Association for Computing Machinery. ISBN 9798400711619. Groves, T. 1973. Incentives in Teams. *Econometrica*, 41(4): 617–631. Hendrycks, D.; Burns, C.; Basart, S.; Zou, A.; Mazeika, M.; Song, D.; and Steinhardt, J. 2021a. Measuring Massive Multitask Language Understanding. arXiv:2009.03300. Hendrycks, D.; Burns, C.; Kadavath, S.; Arora, A.; Basart, S.; Tang, E.; Song, D.; and Steinhardt, J. 2021b. Measuring Mathematical Problem Solving With the MATH Dataset. In Vanschoren, J.; and Yeung, S., eds., Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks, volume 1. Huang, D.; Zhang, J. M.; Luck, M.; Bu, Q.; Qing, Y.; and Cui, H. 2024. AgentCoder: Multi-Agent-based Code Generation with Iterative Testing and Optimisation. arXiv:2312.13010. Jiang, J.; and Lu, Z. 2018. Learning attentional communication for multi-agent cooperation. In NeurIPS, NIPS'18, 7265–7275. Red Hook, NY, USA: Curran Associates Inc. Khan, A.; and et al., J. H. 2024. Debating with More Persuasive LLMs Leads to More Truthful Answers. arXiv:2402.06782. Leon, V.; and Etesami, S. R. 2025. Online Learning for Dynamic Vickrey-Clarke-Groves Mechanism in Sequential Auctions under Unknown Environments. arXiv:2506.19038. Li, W.; Hu, B.; Shao, R.; Shen, L.; and Nie, L. 2025a. Lions: Fast & slow video-language thinker as online video assistant. In Proceedings of the Computer Vision and Pattern Recognition Conference, 3240–3251. Li, W.; Zhang, R.; Shao, R.; He, J.; and Nie, L. 2025b. Cogvla: Cognition-aligned vision-language-action model via instruction-driven routing & sparsification. arXiv preprint arXiv:2508.21046. Li, Y.; and et al., Y. D. 2024. Improving Multi-Agent Debate with Sparse Communication Topology. arXiv:2406.11776. Ling, W.; Yogatama, D.; Dyer, C.; and Blunsom, P. 2017. Program Induction by Rationale Generation: Learning to Solve and Explain Algebraic Word Problems. In Barzilay, R.; and Kan, M.-Y., eds., ACL, 158–167. Vancouver, Canada: Association for Computational Linguistics. Liu, Z.; Zhang, Y.; Li, P.; Liu, Y.; and Yang, D. 2024. A Dynamic LLM-Powered Agent Network for Task-Oriented Agent Collaboration. arXiv:2310.02170. Lo, Y. L.; Sengupta, B.; Foerster, J.; and Noukhovitch, M. 2024. Learning Multi-Agent Communication with Contrastive Learning. arXiv:2307.01403. OpenAI. 2024. GPT-4 Technical Report. arXiv:2303.08774. Patel, A.; Bhattamishra, S.; and Goyal, N. 2021. Are NLP Models really able to Solve Simple Math Word Problems? In Toutanova, K.; Rumshisky, A.; Zettlemoyer, L.; Hakkani-Tur, D.; Beltagy, I.; Bethard, S.; Cotterell, R.; Chakraborty, T.; and Zhou, Y., eds., ACL, 2080–2094. Online: Association for Computational Linguistics. Roy, S.; and Roth, D. 2016. Solving General Arithmetic Word Problems. arXiv:1608.01413. Searle, J. R. 1969. *Speech Acts: An Essay in the Philosophy of Language*. Cambridge University Press. Smith, 1980. The Contract Net Protocol: High-Level Communication and Control in a Distributed Problem Solver. *IEEE Transactions on Computers*, C-29(12): 1104–1113. Suguri, H. 1999. A standardization effort for agent technologies: The Foundation for Intelligent Physical Agents and its activities. In Proceedings of the 32nd Annual Hawaii International Conference on Systems Sciences. 1999. HICSS-32. Abstracts and CD-ROM of Full Papers, volume Track8, 10 pp.–. Tishby, N.; Pereira, F. C.; and Bialek, W. 2000. The information bottleneck method. arXiv:physics/0004057. Vickrey, W. 1961. Counterspeculation, Auctions, and Competitive Sealed Tenders. *The Journal of Finance*, 16(1): 8–37. Wang, L.; Ma, C.; and et al. 2024. A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18(6). Wang, X.; Chen, X.; Ren, W.; Han, Z.; Fan, H.; Tang, Y.; and Liu, L. 2024a. Compensation Atmospheric Scattering Model and Two-Branch Network for Single Image Dehazing. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 8(4): 2880–2896. Wang, X.; Ren, W.; Chen, X.; Fan, H.; Tang, Y.; and Han, Z. 2024b. Uni-YOLO: Vision-Language Model-Guided YOLO for Robust and Fast Universal Detection in the Open World. In Proceedings of the 32nd ACM International Conference on Multimedia, MM '24, 1991–2000. New York, NY, USA: Association for Computing Machinery. ISBN 9798400706868. Wang, X.; Wei, J.; Schuurmans, D.; Le, Q.; Chi, E.; Narang, S.; Chowdhery, A.; and Zhou, D. 2023a. Self-Consistency Improves Chain of Thought Reasoning in Language Models. arXiv:2203.11171. Wang, Z.; Du, Y.; Zhang, Y.; Fang, M.; and Huang, B. 2023b. MACCA: Offline Multi-agent Reinforcement Learning with Causal Credit Assignment. arXiv:2312.03644. Wei, J.; Wang, X.; Schuurmans, D.; Bosma, M.; Ichter, B.; Xia, F.; Chi, E.; Le, Q.; and Zhou, D. 2023. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. arXiv:2201.11903. Wen, Z.; Hu, H.; Fang, N.; Qian, S.; and Cao, J. 2025. DANet: A RAG-inspired Dual Attention Model for Few-shot Time Series Prediction. In Proceedings of the 34th ACM International Conference on Information and Knowledge Management, CIKM '25, 3302–3311. New York, NY, USA: Association for Computing Machinery. ISBN 9798400720406. Yao, S.; Zhao, J.; Yu, D.; Du, N.; Shafran, I.; Narasimhan, K.; and Cao, Y. 2023. ReAct: Synergizing Reasoning and Acting in Language Models. In ICLR. Yu, C.; Velu, A.; Vinitzky, E.; Gao, J.; Wang, Y.;

Bayen, A.; and Wu, Y. 2022. The surprising effectiveness of PPO in cooperative multi-agent games. In *NeurIPS, NIPS '22*. Red Hook, NY, USA: Curran Associates Inc. ISBN 9781713871088.

Zhang, G.; and et al., Y. Y. 2024a. Cut the Crap: An Economical Communication Pipeline for LLM-based Multi-Agent Systems. arXiv:2410.02506.

Zhang, G.; and et al., Y. Y. 2024b. Cut the Crap: An Economical Communication Pipeline for LLM-based Multi-Agent Systems. arXiv:2410.02506.

Zhang, H.; Du, W.; Shan, J.; Zhou, Q.; Du, Y.; Tenenbaum, J. B.; Shu, T.; and Gan, C. 2024. Building Cooperative Embodied Agents Modularly with Large Language Models. arXiv:2307.02485.

Zhang, J.; Cai, K.; Fan, Y.; Liu, N.; and Wang, K. 2025a. MAT-Agent: Adaptive Multi-Agent Training Optimization. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.

Zhang, J.; Cai, K.; Yang, J.; Wang, J.; Tang, C.; and Wang, K. 2025b. Top-Down Semantic Refinement for Image Captioning. arXiv:2510.22391.

Zhang, J.; Cai, K.; Yang, J.; and Wang, K. 2025c. Learning Dynamics of VLM Finetuning. arXiv:2510.11978.

Zhang, J.; Cai, K.; Zeng, Q.; Liu, N.; Fan, S.; Chen, Z.; and Wang, K. 2025d. Failure-Driven Workflow Refinement. arXiv:2510.10035.

Zhang, J.; Fan, Y.; Cai, K.; Huang, Z.; Sun, X.; Wang, J.; Tang, C.; and Wang, K. 2025e. DrDiff: Dynamic Routing Diffusion with Hierarchical Attention for Breaking the Efficiency-Quality Trade-off. arXiv:2509.02785.

Zhang, J.; Fan, Y.; Cai, K.; Sun, X.; and Wang, K. 2025f. OSC: Cognitive Orchestration through Dynamic Knowledge Alignment in Multi-Agent LLM Collaboration. arXiv:2509.04876.

Zhang, J.; Fan, Y.; Cai, K.; and Wang, K. 2025g. Kolmogorov-Arnold Fourier Networks. arXiv:2502.06018.

Zhang, J.; Fan, Y.; Lin, W.; Chen, R.; Jiang, H.; Chai, W.; Wang, J.; and Wang, K. 2025h. GAM-Agent: Game-Theoretic and Uncertainty-Aware Collaboration for Complex Visual Reasoning. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.

Zhang, J.; Fan, Y.; Wen, Z.; Wang, J.; and Wang, K. 2025i. Tri-MARF: A Tri-Modal Multi-Agent Responsive Framework for Comprehensive 3D Object Annotation. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.

Zhao, W. X.; and et al., K. Z. 2025. A Survey of Large Language Models. arXiv:2303.18223.

Zheng, C.; Liu, Z.; Xie, E.; Li, Z.; and Li, Y. 2023. Progressive-hint prompting improves reasoning in large language models. arXiv preprint arXiv:2304.09797.

Zheng, C.; Liu, Z.; Xie, E.; Li, Z.; and Li, Y. 2024. Progressive-Hint Prompting Improves Reasoning in Large Language Models. arXiv:2304.09797.

Zhou, Q.; and et al., Z. Z. 2024. Enhancing the General Agent Capabilities of Low-Parameter LLMs through Tuning and Multi-Branch Reasoning. arXiv:2403.19962.