

FREE-MAD：无需共识的多智能体辩论

英文-中文译文（保留主要图片与公式，附录未处理）

Yu Cui¹ Hang Fu¹ Haibin Zhang² Licheng Wang¹ Cong Zuo¹

¹ 北京理工大学 ² 清华大学长三角研究院（浙江）

cuiyu@bit.edu.cn, bchainzhang@aliyun.com

摘要

多智能体辩论（multi-agent debate, MAD）是一种新兴方法，用于提升大语言模型（LLM）的推理能力。现有 MAD 方法依赖智能体之间多轮交互来达成共识，并在最后一轮通过多数投票选择最终输出。然而，这种基于共识的设计存在若干限制。首先，多轮通信会增加 token 开销并限制可扩展性。其次，由于 LLM 固有的从众性，最初给出正确回答的智能体可能在辩论过程中受到错误回答影响，从而导致错误传播。第三，多数投票会在决策阶段引入随机性与不公平性，并可能降低推理性能。

为解决这些问题，本文提出 FREE-MAD，一个新的 MAD 框架，它不再要求智能体之间达成共识。FREE-MAD 引入了新的基于分数的决策机制：该机制评估整个辩论轨迹，而不是只依赖最后一轮。它追踪每个智能体推理过程的演化，从而获得更准确且更公平的结果。此外，FREE-MAD 通过引入反从众（anti-conformity）来重构辩论阶段，使智能体能够减弱来自多数意见的过度影响。在八个基准数据集上的实验表明，FREE-MAD 只需要单轮辩论即可显著提升推理性能，从而降低 token 成本。我们还表明，相较于现有 MAD 方法，FREE-MAD 在真实攻击场景中具有更强的鲁棒性。

1 引言

大语言模型（LLM）由于具备较强的推理能力，已被广泛应用于聊天机器人 [1]、程序设计 [2]、医疗健康 [3,4] 与网络安全 [5] 等领域。近年来，LLM 智能体 [6] 的应用不断增加，也对 LLM 的推理性能提出了更高要求。为提升 LLM 智能体的推理准确率，许多研究探索了无需训练的方法，例如思维链（Chain-of-Thought, CoT）[7]、自我修正 [8] 与自洽性 [9]。然而，这些方法主要关注单个 LLM 的使用，缺少多个模型之间的协作。相比之下，多智能体辩论（MAD）[10–14] 已成为一种重要解决方案：多名智能体通过多轮交互，能够比单个智能体获得显著更好的推理性能。事实上，MAD 已成功用于软件问题修复 [15]、数学推理 [16] 与代码摘要 [17] 等场景。

现有对 MAD 的优化工作主要关注辩论过程中单个智能体的推理策略 [14]，或提升其可扩展性 [10]。近期研究显示，LLM 智能体会表现出从众性 [18–20]，即在多智能体交互中，智能体倾向于偏好多数人支持的答案。事实上，在现有 MAD 框架中，辩论过程中的从众驱动共识 [21,10,12,22] 通常被认为是得到正确最终答案的必要条件 [13]。然而，更强的共识不仅会降低推理准确率，还需要更多辩论轮次，从而增加 token 消耗并限制可扩展性。这些基于共识的 MAD 方案还会遭遇“沉默式同意”（Silent Agreement）问题 [23]：即使智能体最初意见不同，也会由于从众性而在讨论中保持沉默，最终导致智能体群体给出错误答案。

为克服这些限制，本文提出 FREE-MAD，这是一个无需共识的 MAD 框架，并在辩论阶段与决策阶段都进行了优化。在辩论阶段，我们引入两种互补模式：从众与反从众。尤其是反从众模式利用 CoT 鼓励智能体发现其他智能体输出中的缺陷，而不是把共识当作正确性的标志。在决策阶段，我们提出基于分数的机制，对辩论轮次中的所有中间输出进行评估，而不像传统 MAD 框架那样只关

注最后一轮。通过追踪所有智能体的推理轨迹变化，FREE-MAD 可以在辩论阶段不要求共识的情况下为所有候选回答打分。此外，我们从理论上形式化 MAD 协议，使 FREE-MAD 与现有 MAD 变体之间能够进行比较分析。

我们在八个基准数据集上进行了大量实验，覆盖知识型推理、逻辑推理以及不同难度的数学推理任务。结果表明，与基线方法相比，FREE-MAD 在推理准确率上取得显著提升。尤其是，FREE-MAD 在更少辩论轮次下即可获得更高准确率，从而加速辩论过程并保持良好的可扩展性。此外，我们展示了 FREE-MAD 在真实部署中具有更强的鲁棒性。本文贡献如下：

- 提出一种新的无需共识的 MAD 框架 FREE-MAD，并对辩论阶段和决策阶段进行专门优化；设计了基于分数的决策机制，对各轮中间结果进行评估，使推理过程不再依赖共识。
- 给出 MAD 协议的语法表示，并对 FREE-MAD 与现有机制进行形式化分析。
- 实现 FREE-MAD，并在八个基准数据集上开展大量实验，证明其在推理准确率、可扩展性和鲁棒性方面优于现有协议。

2 相关工作

MAD 协议的演进。 MAD 最初提出时，目标是通过鼓励 LLM 在答案之间达成共识来提升推理能力。然而，这种共识在理论上无法保证，只是在实践中通常可以实现 [12]。此外，当智能体调整其对自生成内容与外部生成内容的信任程度时，共识会更容易达成，但这种调整往往会降低推理准确率。已有研究并未深入探讨导致性能下降的更深层从众问题。后续研究主要关注优化 MAD 的辩论阶段 [13,24,10,25,14]。在这些工作中，共识通常被视为辩论阶段的默认目标 [22]。本文则表明，MAD 即使不要求共识，也可以有效运行。

MAD 协议安全性。 在辩论阶段，传统面向共识的方法在不可靠网络环境中往往缺乏鲁棒性。通信攻击 [26] 可以迫使部分智能体退出辩论，使其无法接收其他智能体的回答；这会延迟共识并增加自适应方案 [25] 的开销，最终降低推理准确率。另一类方法允许智能体同时返回其个人回答和自评置信度 [24]，再将置信度用于加权聚合最终结果。然而，由于 LLM 存在幻觉 [27]，这种置信度可能并不可靠。

现有 MAD 决策机制不足以应对与 LLM 从众性相关的安全风险。在真实部署中，如果少数智能体通过提示注入攻击 [28–30] 被攻陷，系统可能会收敛到一个共享但错误的答案。当采用多数投票等机制进行决策时，这可能导致整个 MAD 系统完全失败。其他方法 [25] 使用 LLM-as-a-Judge [31] 框架，由一个 LLM 判定最终结果。该方法可能产生偏见并容易受到从众影响，在效果上近似于多数投票。此外，如果作为裁判的 LLM 被提示注入攻击攻陷，MAD 系统最终输出的准确率可能显著下降。关于 MAD 中智能体多样性的相关工作，我们在附录 B 中进一步讨论。

3 初步分析

3.1 MAD 协议：形式化的两阶段分解

为便于后续讨论 MAD 最终答案的推导细节，我们将 MAD 协议分解为两个核心阶段：辩论 (Debate) 与决策 (Decision)。辩论阶段内部包含 R 轮迭代，并最终得到一组最终答案。形式化地，给定 N 个智能体集合 $\{a_i\}_{i=1}^N$ ，协议定义为：

$$\{r_i^R\}_{i=1}^N \leftarrow \text{Debate}(\{a_i\}_{i=1}^N, q, p, R) \quad (1)$$

$$r_{\text{final}} \leftarrow \text{Decide}(\{r_i^R\}_{i=1}^N) \quad (2)$$

在辩论阶段，所有智能体基于用户问题 q 与指导提示 p 进行多轮交互；其中 p 指定智能体应如何辩论。辩论从初始步骤开始：每个智能体先对 q 生成初步回答，然后将其广播给其他所有智能体作为辅助上下文 [32]。随后，每个智能体 a_i 在 R 轮中迭代更新自己的答案 r_i^k ，最终得到回答集合 $\{r_i^R\}_{i=1}^N$ 。截至第 $k-1$ 轮的完整发言历史记为上下文 $C^{(k-1)}$ 。我们将 LLM 智能体建模为概率过程，以更准确地刻画其生成行为。在第 k 轮中，智能体 a_i 从以前文上下文与 p 为条件的概率分布中采样生成回答 r_i^k ：

$$r_i^k \sim P_{a_i}(r \mid C^{(k-1)}, p). \quad (3)$$

为研究独立推理与从众之间的相互作用，我们使用一种将二者贡献分离的公式来建模整体概率分布 P_{a_i} ：

$$P_{a_i}(r \mid C^{(k-1)}, p) = \frac{1}{Z} \cdot P_{\text{in}}(r \mid q, p) \cdot \exp(\beta(p) \cdot S_{\text{con}}(r, C^{(k-1)})). \quad (4)$$

其中，独立推理分布 $P_{\text{in}}(r \mid q, p)$ 在数学上刻画智能体在给定问题 q 与提示 p 时的内在推理能力，该能力不包含同伴影响。从众分数 $S_{\text{con}}(r, C^{(k-1)})$ 衡量候选回答 r 与上下文 $C^{(k-1)}$ 中同伴发言的一致程度，其影响由提示 p 决定的从众参数 $\beta(p)$ 进行缩放。默认情况下，LLM 具有从众倾向；当 p 为空或中性时，可用 $\beta_{\text{default}} > 0$ 表示。若 p 鼓励批判性推理，则 $\beta(p)$ 可以为负，相当于一个降低一致性并推动回答趋向 P_{in} 的正则项。相反，若 p 鼓励赞同多数意见，则 $\beta(p)$ 取更大的正值，会加速向共识收敛。最后，模型通过指数变换组合各部分，并用 Z 归一化以保证有效概率分布。

在决策阶段，会从 $\{r_i^R\}_{i=1}^N$ 中选择最终输出 r_{final} ，典型机制包括多数投票。本文中， R 不包括初始回答生成，而是从智能体开始接收其他智能体回答之后计数。

3.2 现有 MAD 方法的弱点

推理准确率。 MAD 方法 [12,32,22] 通常将决策阶段设计为只作用于辩论最后一轮的 N 个回答，却忽略辩论过程中产生的其余 $R \times N$ 个中间回答。这种忽略削弱了早期回答对决定 r_{final} 的影响，从而降低最终结果的准确性与公平性。在基于共识的辩论中，一旦智能体达成一致，过程就会结束，即使该答案是错误的 [24,23]。然而，Du 等人 [12] 已表明，即使没有任何智能体最初给出正确答案，正确答案仍可能在辩论后期出现。因此，提前终止会降低 MAD 解决问题的准确率。

基于经验观察，我们发现多个智能体独立生成的初始回答，可能优于应用 MAD 后得到的辩论结果。如图 1 所示，直接对初始答案进行多数投票可以得到正确结果，而辩论结果可能是错误的。图中展示了三种可能情形：样本 1 中，智能体就错误答案达成共识；样本 2 是理想结果，正确答案“C”占多数；样本 3 这类结果较少受到关注：集合 $\{r_i\}_{i=1}^N$ 中的输出完全不同，没有重复答案，也不存在多个答案票数相同的情况。在这种情况下，最终答案通常要么从 $\{r_i\}_{i=1}^N$ 中随机选取，要么选取第一个回答。这两种策略都会显著降低 MAD 的准确率。因此，多数投票并不适合基于辩论结果进行决策，需要更鲁棒、更实用的机制。




图 1: 现有 MAD 方法得到的最终答案，其准确性可能甚至低于初始答案。

鲁棒性。 大多数现有多智能体系统缺乏拜占庭鲁棒性 [33,34,26]。由于 MAD 依赖共识机制，它更容易受到攻击 [35]。一些研究 [36] 主要通过引入区块链并利用传统分布式共识协议来增强多智能体

系统的鲁棒性。然而，区块链的使用，包括智能合约 [37] 与共识执行 [38,39]，会显著降低整体系统性能。

4 方法

本节首先通过形式化方式介绍本文提出的 FREE-MAD (见 4.1 节)。随后，我们介绍 FREE-MAD 中的两项核心技术：不要求共识的辩论协议 (见 4.2 节) 与基于分数的决策机制 (见 4.3 节)。接着给出 FREE-MAD 的框架设计 (见 4.4 节)。最后，对 FREE-MAD 与现有方法进行分析比较 (见 4.5 节)。

4.1 FREE-MAD

FREE-MAD 关注整个 MAD 过程中产生的完整结果集合，而不是像传统方法那样仅关注最后一轮回答。我们提出的辩论协议将所有回答纳入决策过程。这一视角可以用如下矩阵形式表示：

$$\text{Decide}[\alpha_0, \alpha_1, \dots, \alpha_{R-1}, \alpha_R] = \begin{bmatrix} r_1^0 & r_1^1 & \dots & r_1^{R-1} & r_1^R \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ r_N^0 & r_N^1 & \dots & r_N^{R-1} & r_N^R \end{bmatrix} \rightarrow r_{\text{final}}. \quad (5)$$

其中，被强调的条目对应此前 MAD 方法未考虑的组成部分。 r_i^0 表示智能体 i 生成的初始回答。不同于以往将辩论与决策阶段分离的 MAD 框架，FREE-MAD 创新性地将决策过程整合进辩论阶段，从而形成统一流程 (见图 2)。

4.2 无需共识的辩论

MAD 中的智能体会交换回答，并基于前缀提示更新自己的答案。一个常见提示是“其他智能体的回答如下” [12]。由于 LLM 的从众性，这类提示往往会将智能体偏向多数答案，从而削弱严谨推理，并提高推理错误不被发现的概率。

为缓解这种从众性，我们在前缀提示之后附加了一个基于 CoT 的提示 (见附录 E)，其灵感来自 [18]。我们为智能体提供一个包含恶意智能体的场景，并要求它们仔细评估自身答案与同伴答案之间的差异。智能体只有在明确发现自己的答案错误时才应改变信念，而不是以与他人达成共识为目标。该机制旨在减少 MAD 过程中错误答案的传播。

我们设计的结构化批判性推理提示是优化公式 (4) 中概率模型的核心机制，主要产生两类效果。第一，它提升独立推理分布 P_{in} 的质量。FREE-MAD 要求每个智能体给出答案及详细推理轨迹，并将其纳入下一轮上下文 $C^{(k-1)}$ 。智能体 a_i 会利用该上下文分析同伴推理，而不只是分析其答案。如果多数答案背后的推理存在缺陷，那么 a_i 的批判性思考会在 P_{in} 中为该答案分配很低概率。第二，它平衡从众性。即使一个流行但错误的答案具有较高的 S_{con} ，较低的 P_{in} 也会使其整体概率 P_{a_i} 保持较低。

4.3 基于分数的决策机制

基于现有 MAD 框架 [12] 与传统 MAD 协议的形式化 [11]，我们将本文协议概括为算法 1。该方法维护矩阵 $A \in \mathbb{R}^{N \times (R+1)}$ ，实时记录每个智能体在各轮辩论中的回答。同时，使用分数字典 S 追踪辩论过程中出现的多个答案对应分数。该机制通过追踪智能体是否在各轮之间出现观点转移 (即当前轮回答是否不同于上一轮回答) 来评估某个答案为正确的可能性。由于本框架中的智能体并非追求共识，而是严谨评估答案背后的推理，因此智能体回答的变化可被解释为“发现了更准确答案”

的信号。具体来说，被智能体放弃的答案更可能是错误的，而新采用的答案更可能是正确的。这种动态变化会反映到字典 S 的分数更新中。

算法 1: 基于评分决策的 MAD 协议及其评估

输入: N 个智能体在 R 轮中的回答矩阵 $A \in \mathbb{R}^{N \times (R+1)}$; 任务输入与真实答案 $D_{\text{task}} = \{q_i, r_i^g\}$; 权重 $W = \{w_i\}_{i=1}^4$; 指导提示 p 。

输出: 准确率。

1. 初始化 $\text{success} \leftarrow 0$, 分数字典 $S \leftarrow \emptyset$ 。
2. 对每个 $(q, r^g) \in D_{\text{task}}$: 对 $k = 0$ 到 R , 令 $f = (k+1)^{-1}$; 对每个智能体 $i = 1 \dots N$:
 - 若 $k \neq 0$, 聚合第 $k-1$ 轮其他智能体的回答作为上下文 C , 由 $P_{a_i}(q, p)$ 生成并更新 r_i^k 与矩阵 A 。
 - 记当前回答 $\hat{r} = A[i][k]$ 。若 $k = 0$, 执行 $S[\hat{r}] \leftarrow S[\hat{r}] + w_1 f$ 。
 - 若 $k > 0$, 令上一轮回答 $r_p = A[i][k-1]$ 。若 $\hat{r} \neq r_p$, 则对被转移的答案执行 $S[r_p] \leftarrow S[r_p] - w_2 f$ (若存在), 并执行 $S[\hat{r}] \leftarrow S[\hat{r}] + w_3 f$; 否则执行 $S[\hat{r}] \leftarrow S[\hat{r}] + w_4 f$ 。
3. 删除 S 中键为 **None** 的项目; 令 $MS = \arg \max_k S[k]$ 。若 $|MS| > 1$, 随机从 MS 中选择 r_{final} 以保证鲁棒性; 否则取唯一候选。
4. 若 $r_{\text{final}} = r^g$, 则 $\text{success} \leftarrow \text{success} + 1$ 。返回 $\text{success}/|D|$ 。

我们根据智能体是否在轮次之间改变回答，为答案分配不同权重 $w_i f$ 。其中 $w_i \in W$ 表示系统定义参数， f 是与当前轮次成反比的修正因子。随着轮次增加，每个智能体接收的上下文信息也会增加，因而更容易受到从众影响，尤其是对于基于较小模型的智能体。为限制从众性影响，后续轮次中观点转移的影响通过因子 f 进行降权。我们将 MS 定义为分数最高的答案集合。虽然该集合通常只包含一个候选答案，但我们采用随机选择策略以维持理论鲁棒性。

4.4 框架设计

如 [18] 所指出，LLM 的从众性是一把双刃剑。一方面，它有助于形成共识与一致结果；另一方面，在投票等敏感领域中，它会削弱智能体判断的可靠性。基于反从众的辩论可以缓解智能体盲目从众的负面影响。然而，对于相对简单的任务，LLM 可能表现出过度反从众，导致固执并降低推理准确率。因此，我们认为应根据任务自适应切换从众导向与反从众导向的辩论模式。

为更精细地控制过度从众，分数机制中的权重参数 W 可以被调整，用以调节智能体改变观点与保持原立场之间的平衡。基于这一思想，我们提出由两个子方案组成的 **FREE-MAD** 框架：**FREE-MAD-N** 将反从众辩论过程与基于分数的决策阶段结合；**FREE-MAD-C** 将从众式辩论过程与基于分数的决策阶段结合。这两个方案共同覆盖更广泛的真实应用场景。




图 2: 本文 MAD 框架的推理过程。当正确答案在最后一轮中处于少数时，框架仍能将其识别为最终答案。

4.5 分析

我们将本文提出的 FREE-MAD 框架与现有 MAD 方法进行比较，如表 1 所示。下文进一步分析 FREE-MAD 的优势。

表 1: 本文方法与现有方法的综合比较。

方法	决策方式	反从众	公平性	安全性
Sparse MADLi 等 [22]	多数投票	×	×	×
Liang 等 [25]	LLM-as-a-Judge	×	×	×
ReConcile [24]	加权投票	×	✓	×
ChatEval [13]	多数投票	×	×	×
DMAD [14]	多数投票	×	×	✓
SoM [12]	多数投票	×	✓	✓
FREE-MAD-N	分数	✓	✓	✓
FREE-MAD-C	分数	×	✓	✓

准确性。 FREE-MAD 框架采用无需共识的辩论策略，有助于降低从众影响。这种方法鼓励智能体更多关注推理步骤的正确性，并可能缓解错误传播的影响。此外，现有方法通常需要多轮辩论来达成共识。当轮数 R 较小（例如 $R = 1$ ）时，这些方法可能因缺乏共识而推理性能下降，进而导致准确率降低。相比之下，FREE-MAD 的性能并不与 R 紧密绑定。

可扩展性。 已有工作 [10] 对 MAD 的 token 成本 (TC) 给出了一般复杂度分析: $O(NR^2V + N^2RV + NR|q|)$ ，其中 V 是每个智能体的最大 token 成本。因此，一个实用的 MAD 框架应力求用更少智能体和更少轮次实现高准确率 [14]。共识构建过程通常需要 2 到 3 轮 [24,12,32,40] 才能有效。相比之下，本文方法在理论上只需要单轮辩论，且没有任何共识约束，因此可以显著减少 token 消耗。

安全性。 在通信攻击下，根据我们的分数方案，退出辩论过程的智能体通常只会触发算法 1 中的 $S[\hat{r}] \leftarrow S[\hat{r}] + w_4 f$ ，因为这些智能体的上下文只包含自身先前回答，不会影响整体辩论过程。此外，分数策略完全在 LLM 推理外部执行，并遵循确定性协议，因此不受 LLM 幻觉影响。

公平性。 在辩论阶段，一些方法采用基于角色的辩论策略 [13]，为智能体分配不平等地位并让其执行不同功能。这种设计会强化 LLM 的隐式偏见 [41–43]，并损害 MAD 系统公平性 [40]。相反，FREE-MAD 中的智能体不需要任何预定义角色，所有智能体均以平等身份参与辩论。

5 实验

5.1 实验设置

评估基准。 基于表 1 的比较和 4.5 节的分析，我们选择 SoM 框架 [12] 作为实验基线，以保证公平比较（SoM 也被相关工作 [24,44,22] 广泛用作基线）。此外，本文提出的 FREE-MAD 构建在 SoM 之上，以尽量减少混杂因素影响。在算法 1 中，权重 W 根据理论分析初始化为 $\{20, 25, 30, 20\}$ 。用于评估 FREE-MAD 安全性的实验设置见附录 A。对于消融研究，我们比较了表 2 总结的四种方案，包括本文的 FREE-MAD 与 SoM 基线；该比较突出了我们设计的两个核心模块的有效性。

表 2: 消融实验中多个比较变体的模块配置。

方案	FREE-MAD-N	FREE-MAD-C	基线 1	基线 2 (SoM)
辩论	反从众	从众	反从众	从众
决策	分数	分数	多数投票	多数投票

数据集。 为全面评估 FREE-MAD 的能力，我们在 8 个基准数据集上进行实验。对于数学推理，我们使用 GSM-Ranges [45]（第 4 与第 6 级）、AIME2024、AIME2025 [46] 与 MATH500 [47]。对于逻辑推理，我们使用 StrategyQA [48] 与 MMLU [49] 中的 Logical Fallacies 数据集。对于知识与理论推理，我们采用 AICrypto [50] 中的多项选择题数据集；该数据集是第一个专门用于评估 LLM 密码学能力的基准。

智能体组。 为确保 MAD 框架具备处理本文数据集的基本能力，我们设计了两种 MAD 配置。对于 AIME2024 与 AIME2025，我们基于 Qwen1.5-7B-Chat 与 DeepSeek-V3 [51] 构建 $N = 3$ 的 MAD。对于其他数据集，我们统一使用 Qwen1.5-7B-Chat 和 Qwen2.5-72B-Instruct [52] 构建 $N = 4$ 的 MAD。其他细节见附录。

5.2 评估指标

为评估 MAD 的推理性能与可扩展性，我们同时考察推理准确率与 token 消耗。遵循 [10]，本文采用 token 消耗作为可扩展性指标。准确率按照算法 1 计算；token 消耗定义如下：

$$TC = \sum_{k=0}^R \sum_{i=1}^N T_k^i, \quad (6)$$

其中 T_k^i 表示智能体 a_i 在第 k 轮生成的输出 token 数。

6 主要结果

6.1 推理性能

八个基准上的推理准确率评估结果见图 4 与表 3。总体而言，本文提出的 FREE-MAD 显著优于基线，平均提升分别达到 13.0% 与 16.5%，说明推理性能得到显著增强。尤其是在数学推理任务中，随着问题难度增加，FREE-MAD 的优势更加明显。降低从众性能够明显提升 MAD 的有效性。LLM 推理过程中从众与反从众的具体影响见附录 F；值得注意的是，在反从众条件下，LLM 的推理过程似乎更加理性。

在 MATH500 数据集上，我们观察到，当从众性被抑制时，较弱模型会出现前文提到的推理僵化倾向。在这种情况下，这些模型无法切换到正确的推理路线，导致 FREE-MAD 与基线性能相当。这一限制是预期之内的，因为固定智能体集合不可能在所有任务类别上都达到最优。对于逻辑推理和知识型推理，FREE-MAD 仍显著优于基线。然而，FREE-MAD-C 一直取得比 FREE-MAD-N 更好的结果，因为对于缺乏相关知识的模型而言，反从众下的观点切换往往具有较高随机性。因此，在此类场景中，从众可能带来更有效的结果。通过比较消融研究中的四个变体，我们证明了所提出的核心分数决策机制具有更优性能。




图 3: 多个基准数据集上 MAD 框架的综合比较实验结果。

表 3: 当 $R = 1$ 时，本文方案与基线的推理准确率比较。

方案	FREE-MAD-N	FREE-MAD-C	基线 1	基线 2
准确率	64.43% ($\uparrow 16\%/19\%$)	61.41% ($\uparrow 10\%/14\%$)	55.73%	54.06%

6.2 可扩展性

我们比较了在 $R = 1$ 与 $R = 2$ 条件下四种 MAD 变体的 token 消耗与推理准确率，如图 3 所示。随着辩论轮数增加，MAD 的推理准确率会提升。值得注意的是，FREE-MAD 仅用单轮辩论就能达到与两轮基线 2 相当甚至更高的准确率，同时几乎不带来额外 token 消耗，展现出良好的可扩展性。具体而言，FREE-MAD-N 相较基线取得更强推理准确率，而 FREE-MAD-C 则具有更好的可扩展性。更重要的是，本文方法不再需要通过多轮辩论达成共识，从而显著降低 MAD 系统的执行时间。





图 4: 不同辩论轮数下, 本文方案与基线的 token 消耗和推理准确率比较。

6.3 安全性

与正常场景相比, 基线 1 和基线 2 的准确率均出现显著下降, 最高可达 20% (见图 5)。相比之下, FREE-MAD 始终保持很高准确率。有趣的是, 在某些情况下, 它甚至略高于原始准确率。这种现象可以解释为: 通信攻击阻止部分智能体接收其他智能体的回答, 同时也降低了它们接收错误信息的概率。这些结果表明 FREE-MAD 具有强鲁棒性与安全性。



(a) Experimental results when $R = 1$.

(b) Experimental results when $R = 2$.

Empirical evaluation of the security of MAD frameworks across multiple be

图 5: 通信攻击下, 不同辩论轮数中 MAD 框架在多个基准上的安全性实证评估; 图中比较了推理准确率。

7 结论

本文提出 FREE-MAD, 这是一种新的 MAD 框架, 将可控从众与基于分数的决策机制相结合。不同于传统 MAD 方法, FREE-MAD 不依赖多轮交互, 也不需要达成共识。通过评估整个辩论轨迹而非仅依赖最后一轮, 最终答案的决策准确率得以提升。大量实验表明, 相较于基线协议, FREE-MAD 在推理准确率、可扩展性和抗干扰能力方面均取得显著提升。

说明

本译文覆盖论文正文(摘要至结论), 保留主要图片和公式; 原文附录 A-G 未处理。参考文献题录未全文翻译, 可在原论文中查阅。