

# iMAD: 面向高效且准确 LLM 推理的智能多智能体辩论

Wei Fan, JinYi Yoon, Bo Ji

美国弗吉尼亚理工大学 计算机科学系, Blacksburg, VA, USA

{fanwei, jinyiyoon, boji}@vt.edu

说明: 按你的要求, 附录未处理; 本译文保留正文中的图片与公式。

## 摘要

大语言模型 (LLM) 智能体系统凭借在零样本设置中的强泛化能力而迅速发展。为进一步提升复杂任务上的推理能力与准确率, 多智能体辩论 (Multi-Agent Debate, MAD) 已成为一种很有前景的框架: 它让多个 LLM 智能体围绕同一问题开展结构化辩论, 以激发多样化推理。然而, 对每个查询都触发 MAD 并不高效, 因为这会带来可观的计算开销 (token 成本), 甚至可能通过推翻单智能体的正确答案而降低准确率。为解决这些限制, 本文提出智能多智能体辩论 (intelligent Multi-Agent Debate, iMAD), 一种 token 高效的框架, 只在辩论很可能带来收益时 (即有望纠正初始错误答案时) 才选择性地触发 MAD。为此, iMAD 学习可泛化的模型行为, 以做出准确的辩论决策。具体而言, iMAD 首先提示单个智能体生成结构化自我批判响应, 并从中提取 41 个可解释的语言与语义特征, 用以捕捉犹豫线索; 随后, iMAD 使用轻量级辩论决策分类器, 并通过本文提出的 FocusCal 损失进行训练, 在不针对测试数据集做专门调参的情况下实现稳健的零样本辩论决策。在 6 个 (视觉) 问答数据集上与 5 个强基线进行的大量实验表明, iMAD 在显著减少 token 使用量 (最高 92%) 的同时, 还能提升最终答案准确率 (最高 13.5%)。

代码: <https://github.com/Fanwei100/iMAD>




Figure 1: Overall workflow of iMAD.

图 1: iMAD 的整体工作流程。

## 1 引言

随着大语言模型（LLM）的快速进步，智能体系统已经在（视觉）问答、问题求解、代码生成等任务上展现出令人印象深刻的零样本推理能力。这种无需访问评测数据即可部署的零样本能力，使

LLM 智能体很适合现实世界应用，因为它支持在多种领域中进行快速、可扩展的落地。这类系统通常依赖单个 LLM 智能体，通过思维链（CoT）或 Self-Consistency 等方法生成逐步推理。但单智能体方法往往缺少视角多样性，因此可能忽略替代性的推理路径。

为解决这一问题，近期研究开始探索让多个智能体协作或辩论的多智能体系统，以提升推理与决策质量。在这些方法中，多智能体辩论（MAD）尤其引人注目。它受人类认知中结构化讨论的启发，让多个智能体独立推理、互相批判，并通过结构化交互推动对抗式对话与迭代细化。这种机制能够鼓励多样化推理路径与视角切换，从而帮助模型从初始错误答案中恢复，因此往往优于单智能体系统。

尽管如此，MAD 在实际部署中仍面临两个关键限制。第一，由于需要多轮 LLM 查询，MAD 会显著增加总 token 开销，包括输入 token（发给各智能体的提示）与输出 token（模型生成的回答）。许多 MAD 系统的 token 消耗是单智能体基线的 3 至 5 倍，扩展成本很高。第二，更反直觉的是，MAD 并不会稳定提升回答质量。大量情况下，单智能体的答案本身就是正确的，此时再触发 MAD 属于冗余；另一些情况下，单智能体的错误并不能被 MAD 修正；更糟糕的是，MAD 甚至可能把原本正确的单智能体答案改成错误答案。因此，对所有问题一律使用 MAD 既昂贵，也可能损害准确率。

一个直接思路是使用置信度分数（通常由输出 token 的平均对数概率计算）来估计单智能体答案是否正确。并发工作 DOWN 正是基于这一思路：当置信度低于某个阈值时触发 MAD。但它需要在评测数据的一个子集上调阈值，这违背了零样本设定的核心假设。更重要的是，作者的实证分析表明，单靠置信度并不能可靠判断是否需要辩论。错误答案也可能拥有很高的置信度，暴露出模型过度自信的问题；同时，带有犹豫、矛盾或浅层推理迹象的响应，也常常会得到偏高的分数。

使用重复采样或调用更多智能体，当然可以更稳健地估计是否有必要触发 MAD，但这些方法 token 成本高，难以扩展。因此，本文关注两个核心挑战：（C1）怎样设计一种有效提示，让单智能体响应暴露出更丰富、且可高效提取的辩论决策特征；（C2）怎样在零样本设定下设计一种机制，以智能方式决定何时触发 MAD，从而在不依赖评测集的前提下，识别那些最可能被辩论纠正的错误。

针对这些挑战，本文提出 iMAD——一种面向零样本场景的轻量级辩论触发框架。它只在更可能改善最终答案时触发 MAD。本文的主要贡献如下：

- 针对挑战（C1），提出带结构化自我批判的 iMAD 提示：它要求单个智能体给出初始 CoT 论证、对自身结论的强制性反驳，以及对两种立场分别打分的置信度。该提示在不增加额外输入 token 的前提下，触发一次轻量级“内部小辩论”，并只引入少量输出 token，从而提供丰富的语义与不确定性线索。

- 针对挑战（C2），将“是否触发 MAD”形式化为一个分类问题。从结构化单智能体响应中提取 41 个可解释特征及置信度分数，送入轻量级多层感知机（MLP）分类器。为适应零样本场景，分类器通过本文提出的 Confidence-Calibrated FocusCal 损失学习可泛化的模型行为，其中融合了：非对称焦点损失（LAF）、置信度惩罚（LCP）与期望校准误差（ECE）。
- 在 3 个文本问答数据集与 3 个视觉问答数据集上，iMAD 相比 5 个竞争基线实现了最高 92% 的 token 节省，同时最高提升 13.5% 的准确率。值得注意的是，分类器只在两个具有代表性的数据集上训练，却能有效泛化到 6 个留出测试数据集。

## 2 相关工作

本文将相关研究归纳为三类。其一，单智能体与多智能体 LLM。LLM 在单智能体设定中已表现出较强推理能力，典型方法如 CoT，通过生成中间推理步骤来更好处理复杂任务。Self-Consistency 又进一步通过多次采样并选取最常见答案来提升准确率。但这类方法本质上仍依赖同一个智能体的内部采样，缺乏视角多样性与显式自我纠错。相比之下，多智能体框架让多个智能体独立推理或通过结构化交互协同，从而超越单智能体。

其二，MAD 框架。MAD 是多智能体 LLM 的一种结构化子类：多个智能体围绕同一问题开展显式的辩论性交换，例如批评、反驳或协商，以改进初始输出。既有方法包括角色化辩论、基于输入扰动与聚合的隐式辩论，以及单智能体内部的自我细化。GroupDebate 则进一步将智能体按子群组织，以提高辩论效率。不过，虽然 MAD 提升了可解释性与纠错能力，近期研究也指出它会引入噪声，甚至把单智能体的正确答案推翻成错误答案。

其三，基于置信度的选择性辩论。并发工作 DOWN 尝试根据 LLM 生成的置信度决定是否触发辩论，以降低 MAD 的 token 成本。但该方法需要使用带标注的评测数据来调阈值，违背零样本设定，也削弱了现实可用性。更关键的是，置信度本身并不可靠，往往无法判断触发辩论是否真的会带来改进。

## 3 关键洞见

虽然 MAD 在增强 LLM 推理方面很有潜力，但其部署仍受限，因为有限的准确率增益往往伴随着显著的计算成本。本节首先量化 MAD 相对于单智能体 CoT 的 token 开销，然后分析 MAD 在什么情况下真正有益，最后考察常见不确定性启发式（尤其是置信度）是否能够有效指导辩论触发。

| 数据集   | 单智能体 (CoT) 准确率 | 单智能体平均 Token | MAD 准确率 | MAD 平均 Token |
|-------|----------------|--------------|---------|--------------|
| MEDQA | 76.6           | 653          | 81.9    | 4,034        |
| MMLU  | 86.8           | 764          | 89.5    | 3,348        |
| GSM8K | 71.3           | 618          | 76.4    | 3,446        |

|           |      |       |      |       |
|-----------|------|-------|------|-------|
| OKVQA     | 88.3 | 1,945 | 89.8 | 7,803 |
| VQA-v2    | 77.5 | 2,245 | 81.0 | 8,796 |
| ScienceQA | 86.0 | 1,720 | 89.4 | 6,777 |

表 1: 在 QA 与 VQA 数据集上, 单智能体 CoT 与 MAD 的准确率 (Acc) 和每题平均 token 成本 (# Token) 对比。

(洞见 1) MAD 能提高准确率, 但代价是显著的 token 开销。表 1 显示, MAD 在 6 个数据集上都优于 CoT, 但代价是 token 消耗增加到 3–5 倍; 在 VQA 任务中, 由于视觉输入本身也占用 token, 这种成本更为突出。

| 数据集       | $\mathbf{x} \rightarrow \checkmark$ (%) | $\checkmark \rightarrow \mathbf{x}$ (%) | $\checkmark \rightarrow \checkmark$ (%) | $\mathbf{x} \rightarrow \mathbf{x}$ (%) |
|-----------|-----------------------------------------|-----------------------------------------|-----------------------------------------|-----------------------------------------|
| MEDQA     | 11.9                                    | 6.6                                     | 70.0                                    | 11.5                                    |
| MMLU      | 6.9                                     | 4.2                                     | 82.6                                    | 6.3                                     |
| GSM8K     | 19.1                                    | 14.0                                    | 57.3                                    | 9.6                                     |
| OKVQA     | 4.9                                     | 3.4                                     | 84.9                                    | 6.8                                     |
| VQA-v2    | 9.2                                     | 5.7                                     | 71.8                                    | 13.3                                    |
| ScienceQA | 7.9                                     | 4.5                                     | 81.5                                    | 6.1                                     |

表 2: MAD 结果拆解: 从单智能体 CoT 到 MAD 后, 答案被正确翻转 ( $\mathbf{x} \rightarrow \checkmark$ )、错误翻转 ( $\checkmark \rightarrow \mathbf{x}$ )、二者都对 ( $\checkmark \rightarrow \checkmark$ ) 以及二者都错 ( $\mathbf{x} \rightarrow \mathbf{x}$ ) 的比例。

(洞见 2) MAD 带来的准确率提升主要来自少量样本。理想情况——即 MAD 把单智能体错误答案纠正过来 ( $\mathbf{x} \rightarrow \checkmark$ ) ——在总样本中的占比并不高; 大量辩论要么是冗余的 ( $\checkmark \rightarrow \checkmark$ ), 要么无效 ( $\mathbf{x} \rightarrow \mathbf{x}$ ), 甚至有害 ( $\checkmark \rightarrow \mathbf{x}$ )。这说明把 MAD 不加区分地用于所有问题, 会浪费计算资源, 且可能损害准确率。




Figure 2: Cumulative Density Function (CDF) of confidence scores for correct and incorrect single-agent answers.

图 2: 单智能体正确答案与错误答案的置信度分数累计分布函数 (CDF)。

(洞见 3) 置信度分数并不能可靠指示“辩论是否有益”。作者比较了多种提示策略下的置信度, 发现其分布高度右偏, 与答案正确性或 MAD 是否有效并不充分一致。许多错误答案同样具有很

高置信度，显示出明显的过度自信；一些带有犹豫或浅层推理痕迹的回答也会得到偏高分数。由此可见，仅凭置信度做决策，很容易出现“该辩论时没辩论”或“不该辩论时却辩论”的问题。

## 4 我们的方法：iMAD

本节介绍 iMAD：一种只在更可能纠正初始错误答案时才触发 MAD 的 token 高效框架。它将结构化自我批判提示与轻量级分类器结合起来，在零样本场景下用单智能体输出作出稳健的辩论决策。

### 4.1 框架概览

如图 1 所示，iMAD 包含三大阶段：（i）使用自我批判提示，让单智能体 LLM 生成结构化响应；（ii）从输出中提取可解释特征；（iii）将这些特征输入训练好的辩论决策分类器，以判断是否需要触发 MAD。

第一阶段：生成结构化自我批判的单智能体响应。给定一个输入问题，系统会要求 LLM 输出三部分内容：支持原始答案的初始 CoT 论证、对自身答案提出的反驳性自我批判，以及最终反思——其中包含最终选择的答案，以及对“初始推理”和“自我批判视角”分别给出的显式置信度。这种结构等价于在单个智能体内部激发一次“迷你辩论”：若两种立场都显得有一定说服力，且置信度相近，则说明模型内部存在犹豫，MAD 可能有帮助；反之，若一方明显更强，则答案往往已经趋于确定，无论它最终是对是错。

第二阶段：提取 41 个可解释特征。作者从问题文本、初始推理和自我批判中抽取表层统计量、可读性指标、词性计数、问题类型标记以及与不确定性相关的词汇线索（如模糊表达、转折连接词等）。这些特征能够捕捉人类可理解的“犹豫线索”，从而弥补原始置信度分数无法反映的细粒度不确定性。

第三阶段：由分类器做出辩论决策。iMAD 使用轻量级 MLP 分类器，根据特征向量  $z \in \mathbb{R}^d$  给出一个标量分数  $p \in (0,1)$ ，表示“当前单智能体答案要么已经正确、要么即便错误也不太可能通过辩论挽回”的概率。训练阶段中，每条样本都先经单智能体流程生成答案和自我批判，再根据是否与真值匹配赋予标签  $y$ 。推理阶段则采用阈值  $\tau$ ：当  $p < \tau$  时触发 MAD，否则保留单智能体答案。

### 4.2 使用 FocusCal 损失训练辩论决策分类器

为训练该分类器，本文提出 FocusCal 损失  $L_{FC}$ 。这是一个复合目标，旨在同时处理两个核心问题：一是错误答案上的过度自信；二是置信度与语义犹豫信号之间的不对齐。它由三部分组成：非对称焦点损失  $L_{AF}$ ，用于更强地惩罚“把错误答案判得过高”的情况；置信度惩罚  $L_{CP}$ ，用于让分类器输出与辅助不确定性分数  $u$  对齐；以及期望校准误差 ECE，用于提升分数  $p$  的经验校准性。

具体地，分类器先把输入特征  $z$  输入共享 MLP 编码器  $f_e(\cdot)$ ，再接两个输出头：正确性头  $f_p(\cdot)$  和犹豫性头  $f_u(\cdot)$ ，分别输出两个标量 logit:  $\ell_p$  与  $\ell_u$ 。与此同时，作者把单智能体提供的置信度  $p_{\text{LLM}}$  转换到 logit 空间，与模型内部 logit 融合，以得到最终决策分数  $p$ ，并用  $u$  表示辅助不确定性分数。

$$\ell_p := f_p(f_e(z)), \text{ 且 } \ell_u := f_u(f_e(z)). \quad (1)$$

$$\ell_{\text{LLM}} := \log(p_{\text{LLM}} / (1 - p_{\text{LLM}})). \quad (2)$$

$$p := \sigma(w_1 \cdot \ell_{\text{LLM}} + w_2 \cdot \ell_p + \varepsilon), \quad (3)$$

$$u := \sigma(\ell_u). \quad (4)$$

$$L_{\text{FC}}(y, p, u) := L_{\text{AF}}(y, p) + \lambda \cdot L_{\text{CP}}(y, p, u) + \mu \cdot \text{ECE}(y, p). \quad (5)$$

其中， $w_1$ 、 $w_2$  与  $\varepsilon$  为可学习参数， $\sigma(\cdot)$  为 Sigmoid 函数。这样的双头设计把“最终辩论分数”与“语义犹豫程度”分开建模，从而更容易识别那些虽错误但仍可被辩论挽回的样本。

$L_{\text{AF}}$ （非对称焦点损失）重点惩罚这样一种错误：分类器给事实错误的答案打出过高的分数  $p$ ，导致本应触发的 MAD 被错误跳过。因此作者采用非对称设计，在  $y=0$  时施加更重惩罚，鼓励模型对“看似自信但实际上错误”的答案保持谨慎。

$$L_{\text{AF}}(y, p) := \begin{cases} -\alpha_1 (1-p)^\gamma \log(p), & \text{若 } y = 1, \\ -\alpha_0 p^\gamma \log(1-p), & \text{若 } y = 0. \end{cases} \quad (6)$$

$L_{\text{CP}}$ （置信度惩罚）进一步要求决策分数  $p$  与辅助不确定性分数  $u$  保持一致：若答案错了却给出很高的  $p$ ，说明模型“过度自信”；若答案对了却给出很低的  $p$ ，则说明模型“过度保守”。 $L_{\text{CP}}$  正是用来惩罚这种不一致。

$$L_{\text{CP}}(y, p, u) := \begin{cases} u^2, & \text{若 } y = 0 \text{ 且 } p > \tau, \\ (1-u)^2, & \text{若 } y = 1 \text{ 且 } p < \tau, \\ 0, & \text{其他情况。} \end{cases} \quad (7)$$

ECE（期望校准误差）则从经验校准的角度约束  $p$ ：如果模型给出的分数整体上与真实正确率更一致，那么触发辩论的阈值边界就会更可靠。

$$\text{ECE}(y, p) := \sum_{b=1}^B (1/N) \cdot |\sum_{i \in I_b} p^{(i)} - \sum_{i \in I_b} y^{(i)}|. \quad (8)$$

这三部分共同作用，使分类器既能优先识别“值得辩论”的可恢复错误，又能避免不必要的 MAD。

## 5 实验评估

作者从 token 使用效率（每题 token 使用量）与答案准确率（最终答案是否正确）两个核心维度评估 iMAD，并进一步分析 iMAD 对“跳过辩论”与“触发辩论”的决策质量。附录中还给出了关于推理时间、额外消融以及跨模型评估的更多分析。

数据集方面，本文在 6 个数据集上评估方法，覆盖文本 QA 和图文 VQA：MedQA、MMLU、GSM8K、OKVQA、VQA-v2 与 ScienceQA。

基线方面，作者比较了 5 个强基线：单智能体 CoT、运行 5 次 CoT 并投票的 Self-Consistency (SC)、全量触发辩论的 MAD、GroupDebate (GD)，以及基于置信度触发的选择性辩论方法 DOWN。

分类器配置方面，作者采用了一个 6 层全连接 MLP，每层 200 个隐藏单元，配合批归一化、ReLU 与 0.2 的 dropout；使用 Adam 优化器训练 50 个 epoch，学习率为 0.001。为支持跨任务泛化，分类器只在 PubMedQA 与 GQA 上训练，而不使用任何评测数据。

实现细节方面，主要实验使用 Gemini 2.0 Flash 作为 LLM 智能体，同时在附录中也评估了 GPT-5 nano 和 Qwen 3.0。默认温度为 0，最大输出长度为 512 token。

## 5.1 主要结果

表 3 给出了 iMAD 与单智能体方法、全量 MAD 方法以及选择性 MAD 方法的总体对比。总体来看，iMAD 在显著节省 token 的同时，保持了与最强方法相当甚至更高的准确率。



表 3：各方法在 6 个数据集上的准确率与每题平均 Token

| 数据集       | CoT Acc | CoT Tok | SC Acc | SC Tok | MAD Acc | MAD Tok | GD Acc | GD Tok | DOWN Acc | DOWN Tok | iMAD Acc | iMAD Tok |
|-----------|---------|---------|--------|--------|---------|---------|--------|--------|----------|----------|----------|----------|
| MEDQA     | 76.6    | 653     | 77.3   | 3,482  | 81.9    | 4,034   | 80.2   | 16,832 | 79.2     | 1,161    | 82.0     | 1,300    |
| MMLU      | 86.8    | 764     | 88.2   | 3,772  | 89.5    | 3,348   | 82.6   | 13,216 | 88.3     | 901      | 89.2     | 1,010    |
| GSM8K     | 71.3    | 618     | 74.5   | 3,622  | 76.4    | 3,446   | 73.4   | 15,321 | 72.6     | 812      | 84.8     | 1,025    |
| OKVQA     | 88.3    | 1,945   | 89.2   | 11,031 | 89.8    | 7,803   | 87.3   | 33,932 | 88.1     | 2,344    | 90.3     | 2,601    |
| VQA-v2    | 77.5    | 2,245   | 77.6   | 14,013 | 81.0    | 8,796   | 81.3   | 36,091 | 78.6     | 3,262    | 81.3     | 3,489    |
| ScienceQA | 86.0    | 1,720   | 86.2   | 9,833  | 89.4    | 6,777   | 87.4   | 26,924 | 87.0     | 2,519    | 90.8     | 2,893    |

表 3: iMAD 与各基线在 6 个数据集上的准确率 (Acc) 和每题平均 token 成本 (# Token) 对比。

相较于单智能体与全量 MAD 基线，iMAD 兼顾了高准确率与高 token 效率。虽然 CoT 的 token 最少，但 iMAD 的准确率最高可比 CoT 高出 13.5%。相较于 SC，iMAD 在显著减少 token 的同时，通常还能取得更高准确率。例如在 MEDQA 上，iMAD 相比 SC 减少了 62.7% 的 token，同时将准确率提升了 4.7%。

相较于全量触发辩论的 MAD 与 GD，iMAD 以大幅更低的 token 成本取得相当甚至更高的准确率。以 MEDQA 为例，iMAD 比 MAD 少用 68% 的 token、比 GD 少用 92% 的 token，却获得了最高准确率。在 GSM8K 上，iMAD 甚至比 MAD 高出 8.4 个百分点，这说明“有选择地辩论”优于“逢题必辩”。

相较于基于置信度的 DOWN，iMAD 的 token 开销处于同一量级，但准确率 consistently 更高。DOWN 因为省略了自我批判并会跳过部分本应发生的辩论，所以 token 往往略少；但它难以在零样本场景下仅靠置信度判断何时应辩论。iMAD 虽然为了结构化自我批判与必要的额外辩论多付出少量 token，但能更准确识别“可恢复错误”，因此整体准确率更高。

5.2 iMAD 辩论决策拆解

| 数据集       | 跳过：好<br>$x \rightarrow x$ | 跳过：好<br>$\checkmark \rightarrow \checkmark$ | 跳过：坏<br>$\checkmark \rightarrow x$ | 跳过：坏<br>$x \rightarrow \checkmark$ | 触发：坏<br>$x \rightarrow x$ | 触发：坏<br>$\checkmark \rightarrow \checkmark$ | 触发：坏<br>$\checkmark \rightarrow x$ | 触发：好<br>$x \rightarrow \checkmark$ |
|-----------|---------------------------|---------------------------------------------|------------------------------------|------------------------------------|---------------------------|---------------------------------------------|------------------------------------|------------------------------------|
| MEDQA     | 10.5                      | 66.3                                        | 4.9                                | 4.8                                | 1.0                       | 3.7                                         | 1.7                                | 7.1                                |
| MMLU      | 5.8                       | 80.0                                        | 3.2                                | 3.5                                | 0.5                       | 2.5                                         | 1.1                                | 3.4                                |
| GSM8K     | 6.8                       | 57.1                                        | 11.3                               | 2.9                                | 2.7                       | 0.3                                         | 2.7                                | 16.2                               |
| OKVQA     | 6.8                       | 83.7                                        | 2.8                                | 2.3                                | 0.0                       | 1.2                                         | 0.6                                | 2.6                                |
| VQA-v2    | 12.9                      | 69.7                                        | 5.3                                | 4.9                                | 0.4                       | 2.1                                         | 0.4                                | 4.3                                |
| ScienceQA | 6.1                       | 78.0                                        | 3.6                                | 2.2                                | 0.0                       | 3.5                                         | 0.9                                | 5.7                                |

表 4: iMAD 对“跳过辩论”与“触发辩论”的决策拆解，以及这些决策是有益（Good）还是有害（Bad）。

为评估 iMAD 的选择性辩论触发是否有效，作者预先计算了单智能体输出与 MAD 输出，并以此作为“是否值得辩论”的参考真值。结果表明，iMAD 最多可使 95.9% 的决策属于有益决策。

当 iMAD 选择跳过辩论时，它能够在 65%–80% 的样本上保留单智能体的正确答案 ( $\checkmark \rightarrow \checkmark$ )，同时也能在一部分样本上避免对不可恢复错误浪费计算资源 ( $x \rightarrow x$ )。当 iMAD 选择触发辩论时，它往往能够成功修正原本错误的单智能体答案 ( $x \rightarrow \checkmark$ )。

例如在 GSM8K 上，iMAD 成功修正了 16.2% 的样本；在 MEDQA 上，这一比例为 7.1%，已经接近这些数据集可达到的理论上限。与此同时，有害决策——例如把正确答案翻成错误 ( $\checkmark \rightarrow x$ )，或者在无必要时触发辩论——始终维持在较低水平。

6 结论

本文提出了 iMAD: 一种 token 高效的 MAD 框架, 只在更可能改善结果时触发辩论。它把结构化自我批判提示与通过 FocusCal 损失训练的轻量级辩论决策分类器结合起来, 使系统能够仅基于单智能体响应, 在不使用评测数据的情况下作出有效的零样本辩论决策。相较于 5 个基线, iMAD 最高可减少 92% 的 token 使用量, 同时把准确率提高 13.5%。这些结果表明, iMAD 为 agentic LLM 系统中的协作式推理提供了一种实用、可扩展的方案。未来工作可进一步探索自适应或在线学习方法, 以降低分类器训练时的标注成本并增强泛化能力。

## 致谢

作者感谢 AAAI' 26 的匿名审稿人所提出的建设性意见和建议。本研究部分得到了 NSF grant CNS-2315851、Commonwealth Cyber Initiative (CCI) 以及 Virginia Tech Presidential Postdoctoral Fellowship 的支持。

## 参考文献 (按原文保留)

以下参考文献列表保留英文原文, 以避免学术条目标题与出版信息在翻译过程中产生歧义。

Acknowledgments We sincerely thank the anonymous reviewers of the AAAI'26 for their constructive comments and suggestions. This research was supported in part by NSF grant CNS- 2315851, the Commonwealth Cyber Initiative (CCI), and Virginia Tech Presidential Postdoctoral Fellowship. References Bi, Z.; Chen, K.; Wang, T.; Hao, J.; and Song, X. 2025. CoT-X: An Adaptive Framework for Cross-Model Chain-of-Thought Transfer and Optimization. arXiv:2511.05747. Chen, J.; Saha, S.; and Bansal, M. 2024. ReConcile: Round-Table Conference Improves Reasoning via Consensus among Diverse LLMs. In Ku, L.-W.; Martins, A.; and Srikumar, V., eds., Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 7066–7085. Bangkok, Thailand: Association for Computational Linguistics. Chen, P.; Han, B.; and Zhang, S. 2024. CoMM: Collaborative Multi-Agent, Multi-Reasoning-Path Prompting for Complex Problem Solving. In NAACL-HLT. Chen, S.; Zeng, L.; Raghunathan, A.; Huang, F.; and Kim, T. C. 2024. Moa is all you need: Building llm research team using mixture of agents. arXiv preprint arXiv:2409.07487. Chen, W.; Yuan, J.; Qian, C.; Yang, C.; Liu, Z.; and Sun, M. 2025. Optima: Optimizing Effectiveness and Efficiency for LLM-Based Multi-Agent System. In Che, W.; Nabende, J.; Shutova, E.; and Pilehvar, M. T., eds., Findings of the Association for Computational Linguistics: ACL 2025, 11534–11557. Vienna, Austria: Association for Computational Linguistics. ISBN 979-8-89176-256-5. Cobbe, K.; Kosaraju, V.; Bavarian, M.; Chen, M.; Jun, H.; Kaiser, L.; Plappert, M.; Tworek, J.; Hilton, J.; Nakano, R.; Hesse, C.; and Schulman, J. 2021. Training Verifiers to Solve Math Word Problems. arXiv preprint arXiv:2110.14168. Davenport, J. R. A.; and DeLine, R. 2014. The Readability of Tweets and their Geographic Correlation with Education. arXiv:1401.6058. de Amorim, L. B.; Cavalcanti, G. D.; and Cruz, R. M. 2023. The choice of scaling technique matters for classification performance. Applied Soft Computing, 133: 109924. Eo, S.; Moon, H.; Zi, E. H.; Park, C.; and Lim, H. 2025. Debate Only When Necessary: Adaptive Multiagent Collaboration for Efficient LLM Reasoning. arXiv:2504.05047. Goyal, Y.; Khot, T.; Summers-Stay, D.; Batra, D.; and Parikh, D. 2017. Making the V in VQA Matter: Elevating the Role of Image Understanding in Visual Question Answering. In Conference on Computer Vision and Pattern Recognition (CVPR). Hendrycks, D.; Burns, C.; Basart, S.; Zou, A.; Mazeika, M.; Song, D.; and Steinhardt, J. 2021. Measuring Massive Multitask Language Understanding. In International Conference on Learning Representations. Horovitz, M.; and Goldschmidt, R. 2024. TokenSHAP: Interpreting Large Language Models with Monte Carlo Shapley Value Estimation. In Peled-Cohen, L.; Calderon, N.; and Reichart, R., eds., Proceedings of the 1st Workshop on NLP for Science (NLP4Science), 1–8. Miami, FL, USA: Association for Computational Linguistics. Hsu, C.-J.; Buffelli, D.; McGowan, J.; Liao, F.-T.; Chen, Y.-C.; Vakili, S.; and Shiu, D. 2025. Group Think: Multiple Concurrent Reasoning Agents Collaborating at Token Level Granularity. arXiv:2505.11107. Hudson, D. A.; and Manning, C. D. 2019. GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering. In 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 6693–6702. Jin, D.; Pan, E.; Oufattole, N.; Weng, W.-H.; Fang, H.; and Szolovits, P. 2021. What Disease Does This Patient Have? A Large-Scale Open Domain Question Answering Dataset from Medical Exams. Applied Sciences, 11(14). Jin, Q.; Dhingra, B.; Liu, Z.; Cohen, W.; and Lu, X. 2019. PubMedQA: A Dataset for Biomedical Research Question Answering. In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), 2567–2577. Khediri, A.; Slimi, H.; Yahiaoui, A.; Derdour, M.; Bendjenna, H.; and Ghenni, C. E. 2024. Enhancing Machine Learning Model Interpretability in Intrusion Detection Systems through SHAP Explanations and LLM-Generated Descriptions. In 2024 6th International Conference on Pattern Analysis and Intelligent Systems (PAIS), 1–6. Kingma, D. P.; and Ba, J. 2015. Adam: A Method for Stochastic Optimization. In Bengio, Y.; and LeCun, Y., eds., 3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings. K'oksoy, O. 2006. Multiresponse robust design: Mean square error (MSE) criterion. Applied Mathematics and Computation, 175(2): 1716–1729. Li, Q.; Jia, X.; Zhou, J.; Shen, L.; and Duan, J. 2024a. Re-discovering BCE Loss for Uniform Classification. CoRR, abs/2403.07289. Li, W.; Lin, Y.; Xia, M.; and Jin, C. 2024b. Rethinking Mixture-of-Agents: Is Mixing Different Large Language Models Beneficial? In Language Gamification - NeurIPS 2024 Workshop. Li, Y.; Yuan, P.; Feng, S.; Pan, B.; Wang, X.; Sun, B.; Wang, H.; and Li, K. 2024c. Escape Sky-high Cost: Early-

stopping Self-Consistency for Multi-step Reasoning. In The Twelfth International Conference on Learning Representations. Liang, T.; He, Z.; Jiao, W.; Wang, X.; Wang, Y.; Wang, R.; Yang, Y.; Shi, S.; and Tu, Z. 2024. Encouraging Divergent Thinking in Large Language Models through Multi-Agent Debate. In Al-Onaizan, Y.; Bansal, M.; and Chen, Y.-N., eds., Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing, 17889–17904. Miami, Florida, USA: Association for Computational Linguistics. 8

Liu, T.; Wang, X.; Huang, W.; Xu, W.; Zeng, Y.; Jiang, L.; Yang, H.; and Li, J. 2024. GroupDebate: Enhancing the Efficiency of Multi-Agent Debate Using Group Discussion. arXiv:2409.14051. Lu, P.; Mishra, S.; Xia, T.; Qiu, L.; Chang, K.-W.; Zhu, S.-C.; Tafjord, O.; Clark, P.; and Kalyan, A. 2022. Learn to Explain: Multimodal Reasoning via Thought Chains for Science Question Answering. In The 36th Conference on Neural Information Processing Systems (NeurIPS). Lundberg, S. M.; and Lee, S.-I. 2017. A unified approach to interpreting model predictions. In Proceedings of the 31st International Conference on Neural Information Processing Systems, NIPS’17, 4768–4777. Red Hook, NY, USA: Curran Associates Inc. ISBN 9781510860964. Marino, K.; Rastegari, M.; Farhadi, A.; and Mottaghi, R. 2019. OK-VQA: A Visual Question Answering Benchmark Requiring External Knowledge. In Conference on Computer Vision and Pattern Recognition (CVPR). McCallum, D. R.; and Peterson, J. L. 1982. Computer-based readability indexes. In Proceedings of the ACM ’82 Conference, ACM ’82, 44–48. New York, NY, USA: Association for Computing Machinery. ISBN 0897910850. Nixon, J.; Dusenberry, M. W.; Zhang, L.; Jerfel, G.; and Tran, D. 2019. Measuring Calibration in Deep Learning. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops. OpenAI. 2025. GPT-5 nano. <https://platform.openai.com/docs/models/gpt-5-nano>. Pan, M. Z.; Cemri, M.; Agrawal, L. A.; Yang, S.; Chopra, B.; Tiwari, R.; Keutzer, K.; Parameswaran, A.; Ramchandran, K.; Klein, D.; Gonzalez, J. E.; Zaharia, M.; and Stoica, I. 2025. Why Do Multiagent Systems Fail? In ICLR 2025 Workshop on Building Trust in Language Models and Applications. Shlens, J. 2014. A Tutorial on Principal Component Analysis. arXiv:1404.1100. Srivastava, G.; Bi, Z.; Lu, M.; and Wang, X. 2025. DEBATE, TRAIN, EVOLVE: Self-Evolution of Language Model Reasoning. In Christodoulopoulos, C.; Chakraborty, T.; Rose, C.; and Peng, V., eds., Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing, 32752–32798. Suzhou, China: Association for Computational Linguistics. ISBN 979-8-89176-332-6. Tillmann, A. 2025. Literature Review Of Multi-Agent Debate For Problem-Solving. arXiv:2506.00066. Wan, X.; Sun, R.; Dai, H.; Arik, S.; and Pfister, T. 2023. Better Zero-Shot Reasoning with Self-Adaptive Prompting. In Rogers, A.; Boyd-Graber, J.; and Okazaki, N., eds., Findings of the Association for Computational Linguistics: ACL 2023, 3493–3514. Toronto, Canada: Association for Computational Linguistics. Wang, H.; Prasad, A.; Stengel-Eskin, E.; and Bansal, M. 2024a. Soft Self-Consistency Improves Language Models Agents. In Ku, L.-W.; Martins, A.; and Srikumar, V., eds., Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), 287–301. Bangkok, Thailand: Association for Computational Linguistics. Wang, J.; WANG, J.; Athiwaratkun, B.; Zhang, C.; and Zou, J. 2025. Mixture-of-Agents Enhances Large Language Model Capabilities. In The Thirteenth International Conference on Learning Representations. Wang, X.; Wei, J.; Schuurmans, D.; Le, Q. V.; Chi, E. H.; Narang, S.; Chowdhery, A.; and Zhou, D. 2023. Self-Consistency Improves Chain of Thought Reasoning in Language Models. In The Eleventh International Conference on Learning Representations. Wang, Z.; Mao, S.; Wu, W.; Ge, T.; Wei, F.; and Ji, H. 2024b. Unleashing the Emergent Cognitive Synergy in Large Language Models: A Task-Solving Agent through Multi-Persona Self-Collaboration. In Duh, K.; Gomez, H.; and Bethard, S., eds., Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers), 257–279. Mexico City, Mexico: Association for Computational Linguistics. Wei, J.; Wang, X.; Schuurmans, D.; Bosma, M.; Ichter, B.; Xia, F.; Chi, E.; Le, Q.; and Zhou, D. 2022. Chain-of-thought prompting elicits reasoning in large language models. In Advances in Neural Information Processing Systems, volume 35, 24824–24837. Wu, Q.; Bansal, G.; Zhang, J.; Wu, Y.; Li, B.; Zhu, E. E.; Jiang, L.; Zhang, X.; Zhang, S.; Awadallah, A.; White, R. W.; Burger, D.; and Wang, C. 2024. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. In COLM 2024. Yan, J.; Liu, L.; Pan, Y.; Chen, S.; Yuan, Z.; Xiang, Y.; and Tang, B. 2025. From Long to Lean: Performance-aware and Adaptive Chain-of-Thought Compression via Multi-round Refinement. In Christodoulopoulos, C.; Chakraborty, T.; Rose, C.; and Peng, V., eds., Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing, 12290–12306. Suzhou, China: Association for Computational Linguistics. ISBN 979-8-89176-332-6. Yang, A.; Li, A.; Yang, B.; et al. 2025. Qwen3 Technical Report. arXiv:2505.09388. Yang, D.; Tsai, Y.-H. H.; and Yamada, M. 2025. On Verbalized Confidence Scores for LLMs. In ICLR Workshop: Quantify Uncertainty and Hallucination in Foundation Models: The Next Frontier in Reliable AI. Yang, R.; Rajagopal, D.; Hayati, S. A.; Hu, B.; and Kang, D. 2024. Confidence Calibration and Rationalization for LLMs via Multi-Agent Deliberation. In ICLR 2024 Workshop on Reliable and Responsible Foundation Models. Zhang, H.; Cui, Z.; Chen, J.; Wang, X.; Zhang, Q.; Wang, Z.; Wu, D.; and Hu, S. 2025. Stop Overvaluing Multi-Agent Debate – We Must Rethink Evaluation and Embrace Model Heterogeneity. arXiv:2502.08788. Zhang, Y.; Yang, X.; Feng, S.; Wang, D.; Zhang, Y.; and Song, K. 2024. Can LLMs Beat Humans in Debating? A Dynamic Multi-agent Framework for Competitive Debate. CoRR, abs/2408.04472. 9