

多 LLM 辩论：框架、原则与干预

Multi-LLM Debate: Framework, Principals, and Interventions

Andrew Estornell

ByteDance Research

andrew.estornell@bytedance.com

Yang Liu

University of California, Santa Cruz

yangliu@ucsc.edu

NeurIPS 2024 (第 38 届神经信息处理系统大会)

摘要

大型语言模型具有灵活且通用的特性，因而能够应用于大量基于语言的领域。与人类相似，这些模型也能够通过讨论和辩论来提升答案质量。本文首先从理论角度分析辩论，并给出一个可以对辩论进行数学刻画的框架。在该框架基础上，本文进一步给出若干关于多智能体辩论的理论结果。具体而言，我们证明：当模型能力相近，或者模型响应相似时，辩论动态可能变得静态化，此时辩论过程只是收敛到多数意见。当该多数意见源自共同误解时（这种误解可能由于共享训练数据而被固化到模型中），辩论很可能收敛到与该共同误解相关的答案。基于这些理论结果带来的启发，本文提出三种能够提高辩论有效性的干预方法。对于每一种干预，本文都给出了说明其如何改进辩论的理论结果，并在四个常用基准任务上证明这些干预能够带来更好的性能。

1 引言

大型语言模型（large language models, LLMs）已经表现出以较高效果完成未见任务的显著能力。这种行为通常被称为涌现能力，使 LLM 能够作为通用工具处理广泛的语言任务。其中，一个尤其值得关注的的能力是：LLM 能够接收并处理来自其他模型（或人类）的观点。已有研究表明，这一能力使 LLM 能够通过辩论协作地解决任务。对于给定任务，多智能体辩论的基本流程是：先从每个模型中引出响应，将这些响应分发给各个模型，然后再次从每个模型中引出更新后的响应。

本文旨在探索这一辩论过程。我们首先提出一个理论框架，以便更好地理解辩论。该框架受到贝叶斯推断和上下文学习的启发，说明辩论在一定程度上可以被看作一种特殊类

型的上下文学习。基于该框架，我们给出若干关于辩论过程的理论洞见。特别地，我们展示了多智能体辩论容易受到“回音室效应”的影响。当这种回音室效应来自多数模型共享的误解时，其后果尤其明显；而共享误解可能出现在模型训练数据高度相关等情形中。

随后，我们利用理论框架中的结果提升辩论过程的有效性。具体而言，本文提出三种干预方法，即对辩论过程的修改。第一种是**多样性剪枝**，其目标是在每一轮辩论中最大化模型响应的信息熵；这一方法还能降低回音室效应的严重程度。第二种是**质量剪枝**，其目标是最大化每个模型响应与任务的相关性。我们证明该方法能够提高辩论过程收敛到正确答案的概率。第三种是**误解反驳**，它直接识别并尝试反驳模型响应中的误解。该方法受到一些工作的启发：这些工作表明，与直接给出答案相比，LLM 往往更擅长评估答案。对于每一种干预，我们都给出理论结果，说明其改进辩论的机制。我们还在四个常用基准上进行实验，证明这些干预在实践中能够提升辩论效果。

本文贡献：(1) 提出一个多 LLM 辩论的理论框架，该框架借鉴了上下文学习与贝叶斯推断之间的联系；(2) 给出关于多 LLM 辩论若干关键原则的理论洞见；(3) 基于这些洞见设计三种辩论干预方法，并在四个语言基准（BoolQ、MMLU、MathQ、TruthfulQA）和三类模型家族（GPT、Llama、Mistral）上带来一致的改进。

2 相关工作

本文与多智能体辩论研究密切相关。该方向关注智能体之间通过迭代协作做出决策。相关工作通常将多智能体辩论用于问答任务，并希望通过让多个模型展开讨论，获得比单一模型更高质量的答案。Du 等人提出的初始辩论框架首先向每个模型提出同一问题，然后在后续轮次中，把上一轮所有模型的响应作为上下文，再次向各个智能体提出同一问题。此后，研究者提出了多种变体：例如让模型在辩论中承担不同功能、采用轮转式辩论、动态控制智能体之间的分歧程度，或者引入裁判评估辩手答案的正确性。除辩论外，还有一些迭代提升答案质量的方法，例如思维链、自一致性和自我反思等。

与辩论相似，也有研究考察了不同 LLM 之间的相互交互：例如让 LLM 彼此交流、向其他模型解释自己的理由，或者协同完成一般任务。尽管辩论在许多领域展现出潜力，一些工作也表明，辩论过程可能不稳定，甚至可能比只使用单一模型表现更差。

本文还与上下文学习和贝叶斯推断相关。上下文学习表明，当只提供少量任务示例时，LLM 也能完成未见任务。另有研究指出，上下文学习与贝叶斯推断之间存在联系：提供给模型的额外示例可以被看作对模型关于 token 的后验分布的更新。

3 预备知识

辩论。设 x 是给定问题， y 是其对应答案。例如， $x = \text{“天空是什么颜色？”}$ ， $y = \text{“蓝色”}$ 。遵循 Du 等人提出的辩论流程， n 个 LLM（也称为智能体）通过 T 轮迭代讨论来协作推断正确答案 y ：

- 在第 $t = 0$ 轮，每个智能体 i 观察任务 x ，并给出响应 $z_i^{(0)}$ 。
- 在第 $t > 0$ 轮，每个智能体 i 观察任务 x 以及上一时刻 n 个智能体的输出 $Z^{(t-1)} = (z_1^{(t-1)}, \dots, z_n^{(t-1)})$ ，然后给出响应 $z_i^{(t)}$ 。
- 当 $t = T$ ，或者智能体达成共识时，辩论过程结束。

为了衡量是否达成共识，函数 a 会从给定响应 z 中抽取答案。若 $z = \text{“白天，天空是蓝色的”}$ ，则 $a(z) = \text{“蓝色”}$ 。在第 t 轮，智能体 i 给出响应 $z_i^{(t+1)}$ 的概率为

$$\mathbb{P}_{\text{model}} \left(\underbrace{z_i^{(t+1)}}_{\text{更新后的模型响应}} \mid \underbrace{x}_{\text{任务}}, \underbrace{Z^{(t)} = (z_1^{(t)}, \dots, z_n^{(t)})}_{\text{上一轮所有模型响应}}, \underbrace{\phi_i}_{\text{模型参数}} \right). \quad (1)$$

其中， ϕ_i 表示模型超参数，例如训练数据、架构等。输入 $(Z^{(t)}, x)$ 与超参数 ϕ_i 都会影响输出 $z_i^{(t+1)}$ 。注意，在每一轮中，所有智能体观察到的输入都是相同的，即 $(Z^{(t)}, x)$ 。因此，智能体输出 $z_i^{(t+1)}$ 的差异既由生成过程本身的随机性决定，也由每个模型独有的参数 ϕ_i 决定。为了简化记号，当参数 ϕ_i 已给定时，下文省略 $\mathbb{P}_{\text{model}}$ 的下标，并写作 $\mathbb{P}(\cdot \mid \phi_i)$ 。

本文方法与“普通”辩论的关键区别在于：我们将利用下文讨论的**潜在概念**，在每轮辩论之间修改 $Z^{(t)}$ 中的响应。

潜在概念。本文研究的核心是语言生成中的潜在概念。潜在概念表达这样一种思想：语言并非随机生成，无论是人类还是模型在生成语言时，通常会先形成某种想法或意图，然后选择能够传达这一底层想法或意图的词语。更形式化地，令 Θ 为潜在概念空间， $\theta \in \Theta$ 为一个概念。任务 x 及其对应答案 y 的生成过程可以看作：先选择一个潜在概念向量 $\theta \in \Theta$ ，再采样 $(x, y) \sim D(\theta)$ ，其中 D 是从概念映射到任务—答案对的某个分布。类似地，当模型给出响应时，它会观察 x ，推断潜在概念 θ ，或更一般地推断潜在概念空间上的一个分布，然后按照这些推断概念生成响应。也就是说，式 (1) 中的模型生成概率可表示为

$$\mathbb{P}(z_i^{(t+1)} \mid x, Z^{(t)}, \phi_i) = \prod_{\theta \in \Theta} \mathbb{P}(z_i^{(t+1)} \mid \theta, x, Z^{(t)}, \phi_i) \mathbb{P}(\theta \mid x, Z^{(t)}, \phi_i). \quad (2)$$

对于任意潜在概念空间的选择，上式都可由全概率公式理解。

为了更具体地说明潜在概念，可以考虑 BoolQ 数据集中的问答任务。其中一个问题是：“亚伯拉罕·林肯是否写过电影《拯救大兵瑞恩》中的那封信？”其正确答案是“是”。此处的潜在概念对应电影中的实际场景：林肯写的 Bixby 信被读给一群士兵听。类似地，先抽取一个概念 θ ，例如“这部电影被制作出来”；然后从电影中采样一个字符串 x ，即关于该电影的上述问题。

另一个例子是乘法等算术计算。当我们希望用语言表达乘法时，可能写成“ $4 * 4$ ”。这个字符串背后的潜在概念是乘法机制，例如乘法只是重复加法，而加法本身可以看作数值不断加一的迭代过程。这些例子较易理解；但潜在概念也可以更加抽象，例如某个未知嵌入空间中的向量。

4 多智能体辩论的理论形式化

本节给出多智能体辩论的理论形式化。该形式化有助于理解辩论过程的内部机制，并将用于改进辩论。框架的核心是利用潜在概念，并展开每个模型的生成概率（式（2））来理解辩论。在提出理论框架之前，我们先给出一个重要假设。

假设 4.1. 对于给定潜在概念空间 Θ ，在给定概念 $\theta \in \Theta$ 和模型参数 ϕ_i 的条件下，生成响应 $z_i^{(t+1)}$ 的概率与响应集合 $Z^{(t)}$ 以及任务 x 条件独立，即

$$\mathbb{P}\left(z_i^{(t+1)} \mid \theta, x, Z^{(t)}, \phi_i\right) = \mathbb{P}\left(z_i^{(t+1)} \mid \theta, \phi_i\right).$$

假设 4.1 可以理解为：模型的生成 z_i 由模型参数 ϕ_i 和模型识别出的概念 θ 唯一决定。对于基于编码器—解码器的模型，可以把 ϕ 与 θ 的联合看作编码器产生的嵌入。在获得该嵌入后，原始输入 $(x, Z^{(t)})$ 不再影响模型输出；嵌入和模型参数将唯一决定模型输出。

接下来，本文推导出如下引理，用于考察模型响应在辩论轮次中如何演化。

引理 4.2. 在时间 $t + 1$ ，模型 i 的生成可以表示为

$$\mathbb{P}\left(z_i^{(t+1)} \mid Z^{(t)}, x, \phi_i\right) \propto \underbrace{\sum_{\theta \in \Theta} \mathbb{P}\left(z_i^{(t+1)} \mid \theta, \phi_i\right) \mathbb{P}(x \mid \theta, \phi_i) \mathbb{P}(\theta \mid \phi_i)}_{\text{没有其他智能体时的生成}} \underbrace{\prod_{j=1}^n \mathbb{P}\left(z_j^{(t)} \mid \theta, \phi_i\right)}_{\text{其他智能体导致的偏斜}}.$$

该引理的重要意义在于：我们能够把给定其他模型响应 $Z^{(t)}$ 时生成某个响应 $z_i^{(t+1)}$ 的概率，表示为不考虑其他模型响应时的生成概率与一个由其他模型响应引起的偏斜项的组合。注意，

$$\mathbb{P}\left(z_i^{(t+1)} \mid x, \phi_i\right) \propto \sum_{\theta \in \Theta} \mathbb{P}\left(z_i^{(t+1)} \mid \theta, \phi_i\right) \mathbb{P}(x \mid \theta, \phi_i) \mathbb{P}(\theta \mid \phi_i).$$

因此，可以将 $\mathbb{P}(z_i^{(t+1)} \mid Z^{(t)}, x, \phi_i)$ 看作 $\mathbb{P}(z_i^{(t+1)} \mid x, \phi_i)$ 的加权版本，其权重由偏斜项 $\prod_{j=1}^n \mathbb{P}(z_j^{(t)} \mid \theta, \phi_i)$ 给出。

辩论与上下文学习

为了帮助理解潜在概念在辩论中的作用，我们讨论 Xie 等人关于用潜在概念上的贝叶斯推断理解上下文学习的工作。上下文学习与多智能体辩论之间存在自然联系。上下文学习的过程如下：给定任务 x 和模型 f ，选取若干与 x 相似的任务—答案示例 $(x_1, y_1), \dots, (x_m, y_m)$ ，然后在给定这些示例的条件下让模型 f 回答任务 x ，即 $z = f(x \mid (x_1, y_1), \dots, (x_m, y_m))$ 。Xie 等人的一个关键结果是：示例 (x_j, y_j) 中的潜在概念，尤其是多个示例共同具有的概念，会影响模型答案 z 。如果某个概念的 $\mathbb{P}(\theta \mid (x_1, y_1), \dots, (x_m, y_m))$ 相对其他概念较大，即示例之间存在共享概念 θ ，则模型更可能给出同样共享该概念的响应 z 。

上一轮模型响应 $Z^{(t)}$ 与上下文学习中的示例起到类似作用。模型在时间 $t + 1$ 的更新响应 $z_i^{(t)}$ 会受到 $Z^{(t)}$ 中响应之间共享概念的影响。引理 4.2 中的偏斜项展示了 $Z^{(t)}$ 所传达的潜在概念如何影响 $z_i^{(t)}$ 的生成：具体而言， $\prod_{j=1}^n \mathbb{P}(z_j^{(t)} | \theta, \phi_i)$ 会重新加权模型生成。

4.1 辩论目标

从上述辩论视角出发，我们可以利用概念空间 Θ 设计更有效的辩论流程。为此，本文首先将辩论表述为一个优化问题，其中引理 4.2 中的偏斜项对应优化变量。对于给定任务 x 和答案 y ，每一轮辩论都可以写作如下优化问题：

$$\arg \max_{Z^{(t)}} \sum_{i=0}^n \mathbb{P}(a(z_i^{(t+1)}) = y | Z^{(t)}, \phi_i).$$

在时间 t ，目标是构造响应集合 $Z^{(t)}$ ，使下一时间步给出正确答案的概率最大。将该目标在潜在概念空间 Θ 上展开，可得

$$\arg \max_{Z^{(t)}} \sum_{i=1}^n \sum_{\theta \in \Theta} \left(\mathbb{P}(a(z_i^{(t+1)}) = y | \theta, \phi_i) \mathbb{P}(\theta | \phi_i) \mathbb{P}(x | \theta, \phi_i) \prod_{j=1}^n \mathbb{P}(z_j^{(t)} | \theta, \phi_i) \right). \quad (3)$$

直接优化该目标的关键困难在于：(1) x 和 y 来源的真实概念 θ^* ，以及 $z_j^{(t)}$ 与底层概念之间的关系是未知的；(2) $Z^{(t)}$ 中的响应是自然语言。不过，该形式化仍将帮助我们在概念空间中设计若干方法，以更好地优化辩论。为说明这些方法的动机，我们先对辩论过程本身做出若干观察。

5 辩论原则

本节讨论影响 LLM 辩论有效性的因素。我们特别关注信息多样性的作用，包括 $Z^{(t)}$ 中响应的多样性，以及模型能力的多样性。我们将看到，任意一方面缺乏多样性都会损害辩论过程。最后，我们研究辩论中的一种特殊同质性，即共享误解：大量模型对于任务 x 共享相似的错误信念。

5.1 信息多样性

首先，我们考察模型能力多样性和模型响应多样性如何影响辩论过程。无论是能力同质化，还是响应同质化，都会使辩论过程偏向某些潜在概念。

相似的模型能力。假设辩论过程只使用一种模型，即事实上是同一模型的 n 个副本，也就是对所有 $i \in [n]$ ，都有 $\phi_i \equiv \phi$ 。那么，随着智能体数量增加，辩论过程会更明显地受到回音室效应影响：一轮辩论导致智能体所感知最可能概念发生变化的概率趋近于 0。换言之，更多相似智能体会导致静态化的辩论动态，本质上削弱了辩论本身的意义。

定理 5.1. 假设所有 n 个智能体具有相同配置, 即对所有 i , $\phi_i \equiv \phi$ 。对于 $t > 0$ 的一轮辩论, 令

$$\theta^{(t)} = \arg \max_{\theta \in \Theta} \mathbb{P}(\theta \mid x, Z^{(t)}, \phi), \quad \theta^{(t+1)} = \arg \max_{\theta \in \Theta} \mathbb{P}(\theta \mid x, Z^{(t+1)}, \phi).$$

也就是说, $\theta^{(t)}$ 和 $\theta^{(t+1)}$ 分别是具有参数 ϕ 的模型在给定任务 x 与响应集合 $Z^{(t)}$ 、 $Z^{(t+1)}$ 时最可能推断出的概念。那么, 随着 $n \rightarrow \infty$, 有

$$\mathbb{P}(\theta^{(t)} = \theta^{(t+1)}) \rightarrow 1.$$

定理 5.1 意味着, 当辩论由同一模型 (或非常相似的模型) 的多个副本进行时, 增加模型数量会使辩论集中到单一且不变化的概念上, 而不是在多个概念之间保持平衡分布。

相似的模型观点。 接下来, 我们考察相似响应如何影响协作过程。在时间 t , 设存在 n 个响应 $Z^{(t)}$, 其中至少 m 个响应相似。更具体地说, 存在某个概念 θ' , 使得对所有 $j \leq m$, 都有

$$\theta' = \arg \max_{\theta \in \Theta} \mathbb{P}(\theta \mid z_j^{(t)}, \phi_i).$$

也就是说, 当参数为 ϕ_i 的模型观察这 m 个响应时, 每个响应都具有同一个“最可能”的概念。

定理 5.2. 假设 $Z^{(t)}$ 至少包含 m 个响应, 并且满足

$$\theta' = \arg \max_{\theta \in \Theta} \mathbb{P}(z_i^{(t)} \mid \theta, \phi_i).$$

那么, 当 $m \rightarrow \infty$ 时, 模型在下一轮 ($t+1$) 的生成将由单一概念 θ' 唯一决定。即对于所有有响应对 $z_{(i,1)}^{(t+1)}$ 与 $z_{(i,2)}^{(t+1)}$, 有

$$\frac{\mathbb{P}(z_{(i,1)}^{(t+1)} \mid Z^{(t)}, x, \phi_i)}{\mathbb{P}(z_{(i,2)}^{(t+1)} \mid Z^{(t)}, x, \phi_i)} \rightarrow \frac{\mathbb{P}(z_{(i,1)}^{(t+1)} \mid \theta', \phi_i)}{\mathbb{P}(z_{(i,2)}^{(t+1)} \mid \theta', \phi_i)}.$$

定理 5.2 表明, LLM 辩论容易受到“多数意见支配”。如果大量模型对任务 x 给出相似响应, 那么这些重复答案会淹没其他模型响应以及任务 x 本身所提供的信号。第 7 节将展示这种现象在实践中确实存在。

5.2 共享误解

接下来, 我们研究模型能力与响应同质性中的一种特殊情形: 共享误解。当模型之间共享一种常见误解时, 辩论会变得不那么有效, 并且很可能收敛到与该共享误解相关的错误概念。现在形式化“误解”的定义。

定义 5.3 (误解)。 对于给定概念 θ^* , 若存在另一个概念 θ' , 使得

$$\mathbb{P}_{x \sim D(\theta^*)}(\mathbb{P}(x \mid \theta', \phi_i) > \mathbb{P}(x \mid \theta^*, \phi_i)) > \frac{1}{2},$$

则称参数为 ϕ_i 的模型关于 θ^* 存在误解。也就是说，对于由概念 θ^* 生成的任务，模型认为错误概念 θ' 在超过半数任务上比真实概念 θ^* 更能解释这些任务。

如果 m 个智能体都存在误解，并且共享同一个错误概念 θ' ，则称存在**共享误解**。当模型共享共同误解时，这些模型产生的响应会偏向错误概念 θ' 。

定理 5.4. 令真实概念为 θ^* ，并假设 n 个智能体中有 m 个智能体对于错误概念 θ' 具有共享误解。那么，对于任务和答案 $(x, y) \sim D(\theta^*)$ ，最终第 T 轮辩论过程的期望平均正确性

$$\frac{1}{n} \sum_{i=1}^n \mathbb{P}(a(z_i^{(T)}) = y)$$

随 m 单调下降。

需要注意的是，仅仅加入更多模型并不一定能够缓解向错误概念收敛的现象。当一个模型的误解由训练数据形成时，除非其他模型经过专门训练以避免这类错误，否则由于模型之间训练数据高度相关，其他模型很可能也拥有相同误解。

6 干预方法

本节讨论对辩论过程的若干修改，称为干预。我们将干预分为两类：**剪枝**关注在 $Z^{(t)}$ 中选择保留哪些响应；**修改**关注对 $Z^{(t)}$ 中的响应进行改变或编辑。

6.1 剪枝干预

在第 t 轮辩论中，剪枝干预会在开始下一轮 $t+1$ 之前，从 $Z^{(t)}$ 中仅选择一个响应子集 $Z'^{(t)}$ 。使用剪枝干预时，第 $t+1$ 轮的模型只会看到剪枝后的响应集合 $Z'^{(t)}$ ，而不是完整响应集合 $Z^{(t)}$ 。

多样性剪枝。令 KL 表示 Kullback–Leibler 散度。多样性剪枝会在 $Z^{(t)}$ 中选择 n 个响应中的 k 个，使信息熵最大化，即

$$Z'^{(t)} = \arg \max_{Z \subset Z^{(t)}} \sum_{z_i, z_j \in Z} \text{KL}(D(\theta | z_i), D(\theta | z_j)) \quad \text{s.t. } |Z| = k.$$

质量剪枝。质量剪枝旨在从 $Z^{(t)}$ 中选择与任务 x 相似度最高的 k 个响应。与多样性剪枝类似，质量剪枝会在时间 t 从 n 个响应中选择 k 个；不同之处在于，它不是选择多样性最高的响应，而是选择与问题最相关的响应。具体地，它选择使下式最小的 k 个响应：

$$Z'^{(t)} = \arg \min_{Z \subset Z^{(t)}} \sum_{z_i \in Z} \text{KL}(D(\theta | x), D(\theta | z_i)) \quad \text{s.t. } |Z| = k.$$

在实践中，直接计算 $\text{KL}(D(\theta | x), D(\theta | z_i))$ 或 $\text{KL}(D(\theta | z_i), D(\theta | z_j))$ 是不可行的。因此，可以使用句子嵌入作为这些值的代理。

接下来，我们证明：当模型具有共享误解时，多样性剪枝会降低辩论过程收敛到与该共享误解相对应的错误概念的概率。

定理 6.1. 令真实概念为 θ^* ，并假设至少 $n/2$ 个智能体对于错误概念 θ' 具有共享误解。那么，多样性剪枝会降低辩论收敛到由错误概念 θ' 产生的答案 y' 的概率，即 $y' \sim D(\theta')$ 。

定理 6.2. 对于给定任务—答案对 (x, y) ，质量剪枝会增加辩论收敛到正确答案的概率。令 $Z^{(t)}$ 为时间 t 的全部响应集合， $Z'^{(t)}$ 为质量剪枝后的结果，则

$$\sum_{i=1}^n \mathbb{P}\left(a(z_i^{(t+1)}) = y \mid x, Z'^{(t)}, \phi_i\right) > \sum_{i=1}^n \mathbb{P}\left(a(z_i^{(t+1)}) = y \mid x, Z^{(t)}, \phi_i\right).$$

注 6.3. 如定理 6.1 和 6.2 所示，多样性剪枝会降低辩论收敛到来自某一特定概念的错误答案的概率，而质量剪枝会提高辩论收敛到来自真实概念的正确答案的概率。两种干预可以同时使用，以更有效地引导辩论远离错误答案、靠近正确答案。

6.2 修改干预

误解反驳。除了选择 $Z^{(t)}$ 中哪些响应用于下一轮辩论之外，我们也可以修改 $Z^{(t)}$ 中的响应。误解反驳正是这样一种方法，其目标是将响应 $z_j^{(t)}$ 更新为与任务 x 更相关的形式：

$$z_j^* = \arg \min_z \text{KL}(D(\theta \mid x), D(\theta \mid z)) - \text{KL}(D(\theta \mid z_j^{(t)}), D(\theta \mid z)).$$

与多样性剪枝和质量剪枝类似，上述目标中的分布在实践中不可直接求得。因此，本文使用代理方式更新每个响应 $z_j^{(t)}$ 。具体来说，我们让一个 LLM 对给定响应进行最小修改，得到 z_j^* 。模型首先被提示列出响应中识别出的误解和错误；在给定误解列表后，模型需要提供对误解的反驳以及修正后的响应版本。

定理 6.4. 对于任务—答案对 (x, y) ，误解反驳会提高辩论收敛到正确答案的概率。令 $Z^{(t)}$ 和 $Z^{*(t)}$ 分别表示误解反驳前后的响应集合，则

$$\sum_{i=1}^n \mathbb{P}\left(a(z_i^{(t+1)}) = y \mid x, Z^{*(t)}, \phi_i\right) > \sum_{i=1}^n \mathbb{P}\left(a(z_i^{(t+1)}) = y \mid x, Z^{(t)}, \phi_i\right).$$

7 实验

实验设计。本文在四个常用语言模型基准上进行实验：BoolQ，包含 3270 个是/否问题；MMLU，包含 13869 个多项选择题（本文使用其中 3406 个高中水平问题）；TruthfulQA，包含 817 个开放式问题；以及 MathQ，包含 3000 个形如 $a \cdot b \cdot c + d \cdot e \cdot f$ 的算术问题。在 BoolQ、MMLU 和 MathQ 数据集中，模型正确性通过正则表达式匹配来衡量。在 TruthfulQA 数据集中，模型正确性通过 LLM 裁判衡量（所有实验均使用 GPT-4 作为裁判）。

本文使用四种能力逐渐增强的 LLM：GPT-3.5（GPT-3.5 Turbo）、Llama-2（Llama-2 7B Chat）、Llama-3（Llama-3 8B Instruct）和 Mistral（Mistral 7B Instruct v0.2）。对于句子嵌入

(作为潜在概念 Θ 的代理)，本文使用 ADA-2 的句子嵌入。我们将三种干预方法的组合（记为 Ours）与 Du 等人的辩论范式 Society of Minds (SoM) 进行比较。

首先，本文对多智能体辩论过程做出若干经验观察。

多数意见支配

首先，本文考察模型在多大程度上倾向于同意多数意见。也就是说，当上一轮（第 t 轮）有 m 个模型给出某个特定答案时，模型在第 $t + 1$ 轮给出该特定答案的可能性有多高？例如，在 BoolQ 中，若特定答案是“是”，那么我们希望知道：如果模型在第 t 轮观察到 m 个“是”的答案，它在第 $t + 1$ 轮给出“是”的概率有多高。




图 1: 每个模型在第 $t = 11$ 轮复述多数答案的概率，横轴为第 $t = 0$ 轮给出该多数答案的响应数量（使用 12 个模型进行辩论）。




图 2: 辩论第 0 轮响应多样性与平均准确率提升之间的关系。

为测量这一点，本文首先随机选择一个目标答案，例如“是”；然后提示 11 个模型中的 m 个给出“是”的响应，而其他 $11 - m$ 个模型则被提示给出另一个随机选择的答案。这 11 个响应组成 $Z^{(t)}$ 。随后，本文测试每个模型在观察到 $Z^{(t)}$ 时于第 $t + 1$ 轮给出目标答案的概率，并比较多样性剪枝之前（实心柱）和之后（斜线柱）的情况。

图 1 显示模型容易受到回音室效应的影响，这一现象也由定理 5.1 所预测。当 $Z^{(t)}$ 中包含更多多数答案实例时，模型给出多数答案的可能性也随之增加（即随着 m 增大而增加）。图 1 还表明，多样性剪枝（ $k = 5$ ）能够降低这种回音室效应。

观点多样性

接下来，本文考察 SoM 与本文方法在不同观点多样性下的效果。图 2 展示了 SoM（虚线）和本文方法（实线）相对于单模型性能（即第 $t = 0$ 轮的平均性能）的平均准确率提升，横轴是辩论第 $t = 0$ 轮所有响应之间的相似度（用成对余弦相似度衡量）。可以看到，对于 BoolQ、MMLU 和 TruthfulQA，当响应之间的相似度上升时，SoM 的效果会下降。这一观察与定理 5.1 和 5.2 一致：这些定理表明，在没有干预的情况下，当模型响应过于相似时，辩论效果会下降。

当模型观点更相似（余弦相似度接近 1）时，本文方法相对于 SoM 的提升最大。需要注意的是，MathQ 基准是这些观察的一个反例；该基准中的响应主要由算术展开组成，任意两个算术展开的句子嵌入都会相似，而不论它们真实语义是否相似。因此，在该基准上，嵌入之间的余弦相似度意义较弱。

辩论干预

接下来，本文考察三种辩论干预组合的有效性。完整组合方式见论文算法 1。首先从图 3 中按轮次比较本文方法与 SoM 的性能。可以看到，本文方法相对于普通辩论的优势通常出现在辩论后期。随后，表 1 给出了单模型、SoM 以及三种干预组合的完整结果。在所有情形下，本文方法都与 SoM 相当或优于 SoM。

	Single	SoM	Ours	Single	SoM	Ours
			BoolQ			
6× GPT-3.5	.80±.014	.84±.012	.85±.012	.73±.014	.74±.016	.79±.014
6× Llama-3	.76±.014	.78±.013	.78±.013	.67±.016	.70±.015	.75±.014
6× Llama-2	.67±.017	.68±.017	.73±.016	.41±.017	.47±.018	.52±.018
6× Mistral	.80±.014	.82±.013	.85±.012	.66±.016	.65±.016	.66±.016
3× GPT-3.5 + 3× Llama-3	-	.82±.014	.84±.013	-	.73±.016	.78±.016
3× GPT-3.5 + 3× Mistral	-	.83±.013	.87±.012	-	.69±.017	.72±.016
3× Llama-3 + 3× Mistral	-	.80±.014	.80±.014	-	.69±.017	.74±.016
			TruthfulQA			
6× GPT-3.5	.61±.033	.63±.032	.69±.030	.53±.035	.88±.016	.93±.01
6× Llama-2	.47±.034	.52±.035	.55±.034	.11±.013	.13±.014	.19±.015
6× Llama-3	.53±.035	.55±.032	.55±.032	.25±.016	.33±.017	.48±.018
6× Mistral	.48±.034	.51±.035	.53±.034	.13±.013	.19±.014	.18±.014
3× GPT-3.5 + 3× Llama-3	-	.56±.035	.62±.031	-	.76±.015	.82±.014
3× GPT-3.5 + 3× Mistral	-	.52±.035	.56±.035	-	.56±.018	.68±.017
3× Llama-3 + 3× Mistral	-	.49±.036	.53±.035	-	.22±.015	.23±.015
			Math			

表 1: 单模型、辩论以及本文辩论干预方法的准确率。设置为 10 轮、6 个模型。




图 3: 当组合 GPT-3.5 与 Llama-3 或 Mistral 时, 本文方法和 SoM 的逐轮准确率。

除了给出干预组合的结果, 本文还研究了每种干预单独应用时的效果 (见原文附录表 3)。这些结果表明, 当三种干预同时使用时, 本文方法最为成功。事实上, 某些干预在单独应用时可能对辩论过程产生负面影响。这也是预期之中的, 因为每种干预本身都是为互补配合而设计的。

8 局限性

尽管本文试图解决多 LLM 辩论的一些根本问题, 例如多数意见支配, 但在采用本文框架时仍需考虑若干因素。首先, 理论结果依赖于潜在概念空间, 而该空间在实践中可能不可直接访问, 因此需要使用句子嵌入等代理。对代理的依赖对于质量剪枝和多样性剪枝尤其重要; 在句子嵌入意义较弱的领域, 例如算术问题中, 这些干预的效果会下降。其次, 本文干预会增加辩论过程的推理时间。推理时间增加主要来自误解反驳, 因为该干预需要对每个辩手多次重新提示。

9 结论

多智能体辩论是提升 LLM 响应效果的有效工具。然而, 辩论天然容易受到多数意见支配、模型之间共享误解等问题影响。通过使用本文提出的辩论理论框架, 我们建立了若干辩论过程干预方法, 用于缓解这些问题并提升多智能体辩论的整体性能。实验显示, 多样性剪枝能够降低相似响应的影响; 当多数智能体给出共享同一错误的错误响应时, 这一点尤其有帮助。三种干预的组合能够持续带来更好的辩论效果。

参考文献

以下参考文献条目为原论文参考文献, 保留原文格式以便检索与核对。

Sahar Abdelnabi, Amr Gomaa, Sarath Sivaprasad, Lea Schönherr, and Mario Fritz. Llm-deliberation: Evaluating llms with interactive multi-agent negotiation games. arXiv preprint arXiv:2309.17234, 2023.

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901, 2020.

Chi-Min Chan, Weize Chen, Yusheng Su, Jianxuan Yu, Wei Xue, Shanghang Zhang, Jie Fu, and Zhiyuan Liu. Chateval: Towards better llm-based evaluators through multi-agent debate. *arXiv preprint arXiv:2308.07201*, 2023.

Edward Y Chang. Evince: Optimizing adversarial llm dialogues via conditional statistics and information theory. *arXiv preprint arXiv:2408.14575*, 2024a.

Edward Y. Chang. Llm collaborative intelligence: The path to artificial general intelligence. *SocraSynth.com*, 2024b.

Christopher Clark, Kenton Lee, Ming-Wei Chang, Tom Kwiatkowski, Michael Collins, and Kristina Toutanova. Boolq: Exploring the surprising difficulty of natural yes/no questions. *arXiv preprint arXiv:1905.10044*, 2019.

Yilun Du, Shuang Li, Antonio Torralba, Joshua B Tenenbaum, and Igor Mordatch. Improving factuality and reasoning in language models through multiagent debate. *arXiv preprint arXiv:2305.14325*, 2023.

Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt. Measuring massive multitask language understanding. *arXiv preprint arXiv:2009.03300*, 2020.

Sirui Hong, Xiawu Zheng, Jonathan Chen, Yuheng Cheng, Jinlin Wang, Ceyao Zhang, Zili Wang, Steven Ka Shing Yau, Zijuan Lin, Liyang Zhou, et al. Metagpt: Meta programming for multi-agent collaborative framework. *arXiv preprint arXiv:2308.00352*, 2023.

Geoffrey Irving, Paul Christiano, and Dario Amodei. Ai safety via debate. *arXiv preprint arXiv:1805.00899*, 2018.

Albert Q Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Florian Bressand, Gianna Lengyel, Guillaume Lample, Lucile Saulnier, et al. Mistral 7b. *arXiv preprint arXiv:2310.06825*, 2023.

Hui Jiang. A latent space theory for emergent abilities in large language models. *arXiv preprint arXiv:2304.09960*, 2023.

Akbir Khan, John Hughes, Dan Valentine, Laura Ruis, Kshitij Sachan, Ansh Radhakrishnan, Edward Grefenstette, Samuel R Bowman, Tim Rocktäschel, and Ethan Perez. Debating with more persuasive llms leads to more truthful answers. *arXiv preprint arXiv:2402.06782*, 2024.

Takeshi Kojima, Shixiang Shane Gu, Machel Reid, Yutaka Matsuo, and Yusuke Iwasawa. Large language models are zero-shot reasoners. *Advances in neural information processing systems*, 35:22199–22213, 2022.

Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Hao Yu, Joseph Gonzalez, Hao Zhang, and Ion Stoica. Efficient memory management for large language model serving with pagedattention. In *Proceedings of the 29th Symposium on Operating Systems Principles*, pages 611–626, 2023.

Andrew K Lampinen, Ishita Dasgupta, Stephanie CY Chan, Kory Matthewson, Michael Henry Tessler, Antonia Creswell, James L McClelland, Jane X Wang, and Felix Hill. Can language models learn from explanations in context? *arXiv preprint arXiv:2204.02329*, 2022.

Guohao Li, Hasan Abed Al Kader Hammoud, Hani Itani, Dmitrii Khizbullin, and Bernard Ghanem. Camel: Communicative agents for “mind” exploration of large scale language model society. *arXiv preprint arXiv:2303.17760*, 2023a.

Huaoli, Yu Quan Chong, Simon Stepputtis, Joseph Campbell, Dana Hughes, Michael Lewis, and

Katia Sycara. Theory of mind for multi-agent collaboration via large language models. arXiv preprint arXiv:2310.10701, 2023b.

Yang Li, Yangyang Yu, Haohang Li, Zhi Chen, and Khaldoun Khashanah. Tradinggpt: Multi-agent system with layered memory and distinct characters for enhanced financial trading performance. arXiv preprint arXiv:2309.03736, 2023c.

Yuan Li, Yixuan Zhang, and Lichao Sun. Metaagents: Simulating interactions of human behaviors for llm-based task-oriented coordination via collaborative generative agents. arXiv preprint arXiv:2310.06500, 2023d.

Tian Liang, Zhiwei He, Wenxiang Jiao, Xing Wang, Yan Wang, Rui Wang, Yujiu Yang, Zhaopeng Tu, and Shuming Shi. Encouraging divergent thinking in large language models through multi-agent debate. arXiv preprint arXiv:2305.19118, 2023.

Stephanie Lin, Jacob Hilton, and Owain Evans. Truthfulqa: Measuring how models mimic human falsehoods. arXiv preprint arXiv:2109.07958, 2021.

Zijun Liu, Yanzhe Zhang, Peng Li, Yang Liu, and Diyi Yang. Dynamic llm-agent network: An llm-agent collaboration framework with agent team optimization. arXiv preprint arXiv:2310.02170, 2023.

Meta AI. Meta llama 3. <https://ai.meta.com/blog/meta-llama-3/>, 2024.

Julian Michael, Salsabila Mahdi, David Rein, Jackson Petty, Julien Dirani, Vishakh Padmakumar, and Samuel R Bowman. Debate helps supervise unreliable experts. arXiv preprint arXiv:2311.08702, 2023.

Sewon Min, Xinxu Lyu, Ari Holtzman, Mikel Artetxe, Mike Lewis, Hannaneh Hajishirzi, and Luke Zettlemoyer. Rethinking the role of demonstrations: What makes in-context learning work? arXiv preprint arXiv:2202.12837, 2022.

OpenAI, 2022. URL <https://openai.com/blog/chatgpt/>.

Jeongeon Park, Bryan Min, Xiaojuan Ma, and Juho Kim. Choicemates: Supporting unfamiliar online decision-making with multi-agent conversational interactions. arXiv preprint arXiv:2310.01331, 2023a.

Joon Sung Park, Joseph O’Brien, Carrie Jun Cai, Meredith Ringel Morris, Percy Liang, and Michael S Bernstein. Generative agents: Interactive simulacra of human behavior. In Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology, pages 1–22, 2023b.

Chau Pham, Boyi Liu, Yingxiang Yang, Zhengyu Chen, Tianyi Liu, Jianbo Yuan, Bryan A Plummer, Zhaoran Wang, and Hongxia Yang. Let models speak ciphers: Multiagent debate through embeddings. arXiv preprint arXiv:2310.06272, 2023.

Sumedh Rasal. Llm harmony: Multi-agent communication for problem solving. arXiv preprint arXiv:2401.01312, 2024.

Jie Ren, Yao Zhao, Tu Vu, Peter J Liu, and Balaji Lakshminarayanan. Self-evaluation improves selective generation in large language models. arXiv preprint arXiv:2312.09300, 2023.

Joshua Robinson, Christopher Michael Rytting, and David Wingate. Leveraging large language models for multiple choice question answering. arXiv preprint arXiv:2210.12353, 2022.

Karan Singhal, Tao Tu, Juraj Gottweis, Rory Sayres, Ellery Wulczyn, Le Hou, Kevin Clark, Stephen Pfohl, Heather Cole-Lewis, Darlene Neal, et al. Towards expert-level medical question answering with large language models. arXiv preprint arXiv:2305.09617, 2023.

Andries Smit, Paul Duckworth, Nathan Grinsztajn, Kale-ab Tessera, Thomas D Barrett, and Arnu Pretorius. Are we going mad? benchmarking multi-agent debate between language models for medical q&a. arXiv preprint arXiv:2311.17371, 2023.

Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bash-

lykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, et al. Llama 2: Open foundation and fine-tuned chat models. arXiv preprint arXiv:2307.09288, 2023.

Wen-Kwang Tsao and TrendMicro AILAB. Multi-agent reasoning with large language models for effective corporate planning. In The 10th International Conf. on Computational Science and Computational Intelligence, 2023.

Boshi Wang, Xiang Yue, and Huan Sun. Can chatgpt defend its belief in truth? evaluating llm reasoning via debate. In Findings of the Association for Computational Linguistics: EMNLP 2023, pages 11865–11881, 2023a.

Qineng Wang, Zihao Wang, Ying Su, Hanghang Tong, and Yangqiu Song. Rethinking the bounds of llm reasoning: Are multi-agent discussions the key? arXiv preprint arXiv:2402.18272, 2024.

Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. Self-consistency improves chain of thought reasoning in language models. arXiv preprint arXiv:2203.11171, 2022.

Zhenhailong Wang, Shaoguang Mao, Wenshan Wu, Tao Ge, Furu Wei, and Heng Ji. Unleashing the emergent cognitive synergy in large language models: A task-solving agent through multi-persona self-collaboration. arXiv preprint arXiv:2307.05300, 2023b.

Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35:24824–24837, 2022.

Qingyun Wu, Gagan Bansal, Jieyu Zhang, Yiran Wu, Shaokun Zhang, Erkang Zhu, Beibin Li, Li Jiang, Xiaoyun Zhang, and Chi Wang. Autogen: Enabling next-gen llm applications via multi-agent conversation framework. arXiv preprint arXiv:2308.08155, 2023.

Sang Michael Xie, Aditi Raghunathan, Percy Liang, and Tengyu Ma. An explanation of in-context learning as implicit bayesian inference. arXiv preprint arXiv:2111.02080, 2021.

Jintian Zhang, Xin Xu, and Shumin Deng. Exploring collaboration mechanisms for llm agents: A social psychology view. arXiv preprint arXiv:2310.02124, 2023.