

思维链提示可引发推理 大型语言模型

Jason Wei

布萊恩·伊克特

Xuezhi Wang Dale Schuurmans

夏飞 Ed H. Chi Quoc V. Le Denny Zhou

马尔滕·博斯马

Google Research, Brain Team
{jasonwei, denny Zhou}@google.com

抽象的

我们探讨如何生成一条思路链——一系列中间推理过程。

步骤 显著提高了大型语言模型执行任务的能力

复杂的推理能力。我们尤其展示了这种推理能力是如何产生的。

在足够大的语言模型中,可以通过一种称为“思维链提示”的简单方法自然地实现这一点,其中会提供一些思维链示例。

提示中的范例。

对三个大型语言模型进行的实验表明,思维链提示

提高一系列算术、常识和符号运算能力

推理任务。实证结果可能非常显著。例如,提示

PaLM 540B 仅需八个思维链示例即可达到最先进的水平

在GSM8K数学应用题基准测试中,准确率甚至超过了……

使用验证器对 GPT-3 进行微调。

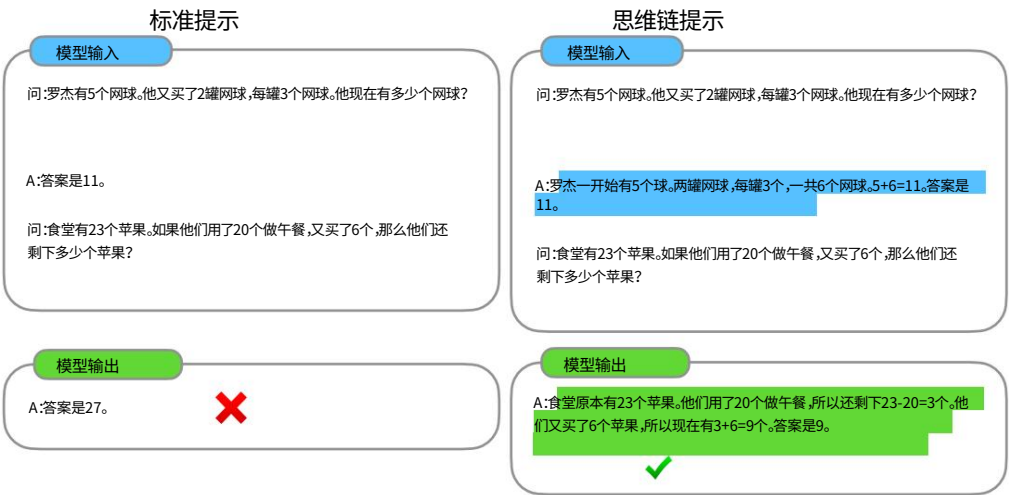


图 1:思维链提示使大型语言模型能够处理复杂的算术运算, 常识推理和符号推理任务。重点强调链式推理过程。

1 引言

近年来,语言模型彻底改变了自然语言处理 (NLP)领域 (Peters et al., 2018; Devlin et al., 2019; Brown et al., 2020等)。研究表明,扩大语言模型的规模可以带来诸多益处,例如提升性能和样本效率 (Kaplan et al., 2020; Brown et al., 2020等)。然而,仅靠扩大模型规模不足以在算术、常识和符号推理等高难度任务中取得优异的性能 (Rae et al., 2021)。

本文探讨了如何通过一种受两个理念启发的简单方法来提升大型语言模型的推理能力。首先,算术推理技术可以受益于生成最终答案的自然语言解释。以往的研究已经通过从头开始训练 (Ling et al., 2017)或微调预训练模型 (Cobbe et al., 2021)赋予模型生成自然语言中间步骤的能力,此外,还有使用形式语言而非自然语言的神经符号方法 (Roy and Roth, 2015; Chiang and Chen, 2019; Amini et al., 2019; Chen et al., 2019)。其次,大型语言模型为通过提示进行情境中少样本学习提供了令人兴奋的前景。也就是说,无需为每个新任务单独微调语言模型检查点,只需用几个演示任务的输入输出示例来“提示”模型即可。值得注意的是,这种方法在一系列简单的问答任务中都取得了成功 (Brown et al., 2020)。




图 2:PaLM 540B 使用思维链提示,在 GSM8K 数学应用题基准测试中取得了新的最先进性能。

微调后的 GPT-3 和先前的最佳结果来自Cobbe 等人(2021)。

然而,上述两种方法都存在关键局限性。对于基于推理增强的训练和微调方法而言,构建大量高质量推理信息成本高昂,远比普通机器学习中的简单输入输出对复杂得多。而Brown等人 (2020)使用的传统少样本提示方法,在需要推理能力的任务上表现不佳,并且随着语言模型规模的扩大,其性能往往没有显著提升 (Rae等人, 2021)。本文将这两种方法的优势结合起来,从而避免了它们的局限性。

具体而言,我们探讨了语言模型在给定由三元组 (输入、思路链、输出)组成的提示时,执行少样本提示推理任务的能力。思路链是指一系列中间自然语言推理步骤,最终导向输出,我们将这种方法称为思路链提示。图1 展示了一个提示示例。

我们对算术、常识和符号推理基准测试进行了实证评估,结果表明,基于思维链的提示方法优于标准提示方法,有时甚至优势显著。图2展示了其中一项结果 在 GSM8K 数学应用题基准测试 (Cobbe 等人, 2021)上,使用 PaLM 540B 的基于思维链的提示方法大幅优于标准提示方法,并达到了新的最佳性能。仅使用提示方法非常重要,因为它不需要庞大的训练数据集,并且单个模型检查点即可执行多项任务而不会损失通用性。这项工作强调了大型语言模型如何通过少量自然语言数据示例来学习任务 (与通过大型训练数据集自动学习输入和输出的潜在模式不同)。

2. 思维链提示

设想一下,在解决复杂的推理任务 (例如多步骤数学应用题)时,人们的思考过程是怎样的。通常的做法是将问题分解成若干中间步骤,逐一解决后再得出最终答案:“简给了妈妈2朵花,她现在有10朵花……然后她给了爸爸3朵花,她现在有7朵花……所以答案是7。”本文的目标是赋予语言模型生成类似思维链的能力 一系列连贯的中间推理步骤,最终得出问题的答案。我们将证明,足够大的

如果在少样本提示的示例中提供思维链推理的演示,语言模型就可以生成思维链。

图1展示了一个模型生成思路链以解决数学应用题的示例,否则该模型会给出错误的答案。在这种情况下,思路链类似于一个解决方案,可以被解释为解决方案,但我们仍然选择称其为思路链,以便更好地体现它模拟了得出答案的逐步思考过程(此外,解决方案/解释通常在最终答案之后出现(Narang 等人, 2020; Wiegrefe 等人, 2022; Lampinen 等人, 2022,等等))。

思维链提示作为一种促进语言模型推理的方法,具有几个有吸引力的特性。

- 1.首先,从原则上讲,思维链允许模型将多步骤问题分解为中间步骤,这意味着可以将额外的计算分配给需要更多推理步骤的问题。
- 2.其次,思路链提供了一个可解释的窗口,让我们得以了解模型的行为,从而了解模型是如何得出特定答案的,并提供了调试推理路径出错之处的机会(尽管完全描述支持答案的模型计算仍然是一个开放性问题)。
- 第三,思维链推理可以用于数学应用题、常识推理和符号操作等任务,并且(至少在原则上)有可能适用于人类可以通过语言解决的任何任务。
- 4.最后,只需将思维链序列的例子添加到少样本提示的示例中,就可以在足够大的现成语言模型中轻松引出思维链推理。

在实证实验中,我们将观察思维链提示在算术推理(第3节)、常识推理(第4节)和符号推理(第5节)中的效用。

3 算术推理

我们首先考虑图1所示的数学应用题,这类题目用于衡量语言模型的算术推理能力。虽然对人类来说算术推理很简单,但语言模型往往难以胜任这项任务(Hendrycks 等人, 2021; Patel 等人, 2021等)。值得注意的是,当使用 540B 参数语言模型并结合思维链提示时,其在多个任务上的表现与针对特定任务进行微调的模型相当,甚至在极具挑战性的 GSM8K 基准测试中取得了新的最佳成绩(Cobbe 等人, 2021)。

3.1 实验装置

我们针对多个基准测试,探索了各种语言模型的思维链提示。

基准测试。我们考虑以下五个数学应用题基准测试集:(1) GSM8K数学应用题基准测试集(Cobbe 等人, 2021), (2) SVAMP数学应用题数据集(包含不同结构的数学应用题)(Patel 等人, 2021), (3) ASDiv数学应用题数据集(包含各种类型的数学应用题)(Miao 等人, 2020), (4) AQUA代数应用题数据集,以及(5) MAWPS基准测试集(Koncel-Kedziorski 等人, 2016)。示例题见附录表12。

标准提示。对于基线模型,我们采用Brown等人(2020)推广的标准少样本提示方法。在该方法中,语言模型在对测试时的示例进行预测之前,会先获得上下文相关的输入输出对示例。示例以问答的形式呈现。模型直接给出答案,如图1(左)所示。

思维链提示。我们提出的方法是在少样本提示中,为每个示例添加一个与答案相关的思维链,如图1(右)所示。由于大多数数据集只有评估部分,我们手动构建了一组包含八个少样本示例的思维链提示集。图1(右)展示了一个思维链示例,完整的示例集见附录表20。(这些示例未经过提示工程处理;鲁棒性研究见第3.4节和附录A.2。)为了探究这种形式的思维链提示是否能够成功地在各种情况下引出有效的推理,



图 3: 算术、常识和逻辑的输入、思维链、输出三元组示例
符号推理基准。思路链已突出显示。完整提示见附录G。

对于数学应用题, 我们使用了这套包含八个思路链示例的单一题集作为所有基准测试的题目。除了AQuA之外, 它采用的是选择题而不是简答题。对于AQuA, 我们使用了四个示例。以及训练集中的解, 如附录表 21 所示。

语言模型。我们评估了五个大型语言模型。第一个是GPT-3 (Brown 等人, 2020), 其中我们使用了 text-ada-001、text-babbage-001、text-curie-001 和 text-davinci-002, 推测分别对应于参数为 350M、1.3B、6.7B 和 175B 的 InstructGPT 模型 (欧阳 等, 2022)。第二个是LaMDA (Thoppilan 等, 2022), 它有 422M、2B、8B 等模型, 第三种是PaLM, 它有68B、62B和540B三种参数的模型。第四个是UL2 20B (Tay等人, 2022), 第五个是Codex (Chen等人, 2021, code-davinci-002)。在 OpenAI API 中)。我们通过贪婪解码从模型中采样 (尽管后续研究表明通过选取多数人的最终答案而非多个样本答案, 可以改进思路链提示 (Wang et al., 2022a))。对于LaMDA, 我们报告了五个随机种子的平均结果, 其中每个种子都对应着不同的、随机打乱顺序的样本。正如 LaMDA 实验所示不同种子之间的差异并不大, 为了节省计算资源, 我们仅报告单个种子的结果。所有其他型号的示例订单。

3.2 结果

图 4 总结了链式思维提示法的最显著结果, 所有实验数据均来自该图。附录表2显示了每个模型集合、模型大小和基准的输出结果。有三个关键点。首先, 图4显示, 思维链提示是一种涌现现象。模型规模的能力 (Wei et al., 2022b)。也就是说, 思维链提示并不能带来积极的影响。对小型模型的影响较大, 只有在与大型模型一起使用时才能获得性能提升。约100B个参数。我们定性地发现, 规模较小的模型能够产生流畅但不合逻辑的表达式。思维链导致表现不如标准提示。

其次,对于更复杂的问题,思路链提示能带来更大的性能提升。例如,对于 GSM8K (基线性能最低的数据集),规模最大的 GPT 和 PaLM 模型的性能提升超过一倍。另一方面,对于 MAWPS 中最简单的子集 SingleOp (只需一步即可解决),性能提升要么为负值,要么非常小(参见附录表3)。

第三,通过 GPT-3 175B 和 PaLM 540B 进行的思维链提示与之前的最佳技术相比具有优势,后者通常在标记的训练数据集上微调特定任务的模型。

图4展示了 PaLM 540B 如何利用链式思维提示在 GSM8K、SVAMP 和 MAWPS 数据集上达到新的最先进水平(但需要注意的是,标准提示在 SVAMP 数据集上已经超越了之前的最佳水平)。在另外两个数据集 AQuA 和 ASDiv 上,采用链式思维提示的 PaLM 的性能与最先进水平的差距在 2% 以内(见附录表2)。

为了更好地理解为什么思维链提示有效,我们手动检查了 LaMDA 137B 为 GSM8K 生成的思维链。在模型返回正确最终答案的 50 个随机示例中,所有生成的思维链在逻辑和数学上都是正确的,只有两个偶然得出正确答案的例子(有关正确的模型生成的思维链示例,请参见附录 D.1 和表8)。




图 4:链式思维提示使大型语言模型能够解决复杂的数学问题。值得注意的是,链式思维推理是一种随着模型规模增大而涌现的能力。

先前的最佳数据来自Cobbe 等人(2021)针对 GSM8K、Jie 等人(2022)针对 SVAMP 以及Lan等人(2021)针对 MAWPS。

我们还随机抽取了 50 个模型给出错误答案的随机样本进行检查。

分析结果表明,46%的推理链几乎完全正确,仅存在一些细微错误(例如计算器错误、符号映射错误或缺少一个推理步骤),而其余54%的推理链在语义理解或连贯性方面存在重大错误(见附录D.2)。为了初步了解模型缩放为何能提升推理链能力,我们对PaLM 62B的错误进行了类似的分析,并考察了缩放至PaLM 540B是否能修正这些错误。结果表明,将PaLM缩放至540B可以修正62B模型中大部分缺少一个步骤和语义理解方面的错误(见附录A.1)。

3.3 消融研究

观察到的思维链提示的益处自然引出了一个问题:其他类型的提示是否也能带来同样的绩效提升?图5展示了一项消融研究,该研究采用了下文所述的三种思维链提示变体。

仅提供方程式。逻辑推理提示之所以有效,原因之一在于它能生成待评估的数学方程式。因此,我们测试了一种变体,即在给出答案之前,提示模型仅输出一个数学方程式。图5显示,仅提供方程式提示对 GSM8K 数据集的帮助不大,这意味着GSM8K 中问题的语义过于复杂,无法在不借助逻辑推理步骤的情况下直接转化为方程式。然而,对于单步或两步问题的数据集,我们发现仅提供方程式提示确实能提高性能,因为方程式可以很容易地从问题中推导出来(参见附录表6)。

仅进行变量计算。另一种直觉是,逻辑思维允许模型将更多计算资源 (即中间步骤) 用于更复杂的问题。为了将变量计算的影响与逻辑思维的影响区分开来,我们测试了一种配置,在该配置中,模型被提示输出一个仅包含点 (...) 的序列,其长度等于解决问题所需的方程式字符数。该变体的性能与基线基本相同,这表明变量计算本身并非逻辑思维提示成功的原因,并且通过自然语言表达中间步骤似乎确实有效。

回答后的思路链。思路链提示的另一个潜在好处在于,它可以帮助模型更好地获取预训练期间获得的相关知识。因此,我们测试了一种替代配置,即仅在回答之后才给出思路链提示,以检验模型是否真的依赖于生成的思路链来给出最终答案。该变体的性能与基线基本相同,这表明思路链中蕴含的顺序推理除了激活知识之外,还有其他用途。




图 5:使用 LaMDA 137B 和 PaLM 540B 对不同提示变体进行消融研究。

其他数据集的结果见附录表6和表7。

3.4 思维链的稳健性

对示例的敏感性是提示方法的一个关键考虑因素。例如,改变少样本示例的排列组合可以使 GPT-3 在 SST-2 上的准确率从接近随机水平 (54.3%) 到接近最先进水平 (93.4%) 不等 (Zhao et al., 2021)。在本节的最后一个小节中,我们评估了对不同标注者编写的思路链的鲁棒性。除了上述使用标注者 A 编写的思路链的结果外,本文的另外两位合作者 (标注者 B 和 C) 也独立地为相同的少样本示例编写了思路链 (见附录 H)。标注者 A 还编写了另一个比原始思路链更简洁的思路链,其风格与 Cobbe et al. (2021) 中给出的解决方案类似。

图6展示了 LaMDA 137B 在 GSM8K 和 MAWPS 数据集上的结果 (其他数据集的消融结果见附录表6 / 表7)。尽管不同的思维链标注之间存在差异,正如使用基于范例的提示时所预期的那样 (Le Scao 和 Rush, 2021; Reynolds 和 McDonell, 2021; Zhao 等人, 2021), 但所有思维链提示集都显著优于标准基线。这一结果表明,成功运用思维链并不依赖于特定的语言风格。

为了验证这种成功的思维导图提示方法对其他示例集也有效,我们还使用从 GSM8K 训练集中随机抽取的三组各八个示例集进行了实验,这些示例集是独立的。




图 6:思维链提示对于不同的提示示例存在差异 (正如预期的那样),但对于不同的标注者以及不同的示例,其性能都优于标准提示。

¹例如,原先的思路使用了几个短句 (“最初有9台电脑。连续4天,每天增加5台电脑。所以一共增加了5 * 4 = 20台电脑。9 + 20 = 29。”),而简洁的思路则是 “增加了5 * 4 = 20台新电脑。所以现在服务器机房里有9 + 20 = 29台新电脑”。

来源（该数据集中的示例已经包含了推理步骤，例如思路链）。图6显示，这些提示与我们手动编写的示例表现相当，并且也大大优于标准提示。

除了对标注者、独立编写的思路链、不同的范例和各种语言模型具有鲁棒性之外，我们还发现，算术推理的思路链提示对不同的范例顺序和不同数量的范例也具有鲁棒性（见附录A.2）。

4. 常识推理

尽管思维链特别适用于数学应用题，但其基于语言的特性实际上使其适用于一大类常识推理问题，这类问题涉及在假定具备一般背景知识的前提下，对物理和人际互动进行推理。常识推理是与世界互动的关键，但目前的自然语言理解系统仍然无法触及（Talmor et al., 2021）。

基准测试。我们考虑了五个数据集，涵盖了各种常识推理类型。

流行的CSQA（Talmor 等人，2019）提出关于世界的常识性问题，这些问题涉及复杂的语义，通常需要先验知识。StrategyQA（Geva 等人，2021）要求模型推断多跳策略来回答问题。我们从 BIG-bench 项目（BIG-bench 合作组，2021）中选择了两个专门的评估数据集：日期理解（Date Understanding），涉及从给定的上下文中推断日期；以及体育理解（Sports Understanding），涉及判断与体育相关的句子是否合理。最后，SayCan数据集（Ahn 等人，2022）涉及将自然语言指令映射到离散集中的一系列机器人动作。图3展示了所有数据集的示例及其思路标注。

提示。我们沿用上一节的实验设置。对于 CSQA 和 StrategyQA，我们从训练集中随机选取样本，并手动构建思路链，作为少样本示例。由于 BIG-bench 的两个任务没有训练集，我们从评估集中选取前十个样本作为少样本示例，并报告评估集中其余样本的数据。对于 SayCan，我们使用了Ahn 等人(2022)训练集中的六个样本，并手动构建了思路链。

结果。图7展示了 PaLM 的结果（LaMDA、GPT-3 和不同模型规模的完整结果见表4）。对于所有任务，扩大模型规模均能提升标准提示的性能；链式提示则进一步提升了性能，其中PaLM 540B 的提升最为显著。采用链式提示后，PaLM 540B相对于基线模型取得了优异的性能，在 StrategyQA 任务上超越了以往的最佳模型（75.6% 对69.4%），在体育理解任务上也优于未经辅助的体育爱好者（95.4% 对 84%）。

这些结果表明，思维链提示还可以提高需要一系列常识推理能力的任务的表现（尽管值得注意的是，在 CSQA 上的提升微乎其微）。




图 7:思维链提示也能提升语言模型的常识推理能力。此处展示的语言模型为 PaLM。先前的最佳成绩来自CSQA（Talmor 等，2019）和 StrategyQA（Geva 等，2021）的排行榜（截至 2022 年 5 月 5 日，仅限单模型）。表4展示了使用不同规模的 LaMDA、GPT-3 和 PaLM 的更多结果。

2. 我们选取样本长度 ≤ 60 个词元以适应输入上下文窗口，并且样本长度 ≤ 2 。
为实现与我们编写的八个范例的公平比较，需要采取以下步骤。

5 符号推理

我们最后的实验评估考虑了符号推理,这对人类来说很简单,但对语言模型来说却可能具有挑战性。我们证明,思维链提示不仅使语言模型能够执行在标准提示设置下具有挑战性的符号推理任务,而且还有助于将推理时间输入的长度泛化到比少样本示例中更长的输入。

任务。我们使用以下两个玩具任务。

·尾字母连接。此任务要求模型连接姓名中单词的尾字母(例如,“Amy Brown” → “yn”)。³这是首字母连接的更难版本,语言模型无需思考即可完成首字母连接任务。³我们通过从姓名普查数据(<https://namecensus.com/>)中随机连接前一千个常用名和姓氏来生成完整姓名。·抛硬币。这项任务要求模型回答在人们抛掷或不抛掷硬币后,硬币是否仍然正面朝上(例如,“一枚硬币正面朝上。菲比抛掷了硬币。奥斯瓦尔多没有抛掷硬币。硬币还是正面朝上吗?” → “否”)。




图 8: 在两个符号推理任务中,使用思维链提示有助于推广到更长的序列。

由于这些符号推理任务的构建方式是明确的,因此对于每个任务,我们都考虑一个领域内测试集,其中的示例与训练/少样本示例的步骤数相同;以及一个领域外 (OOD) 测试集,其中评估示例的步骤数多于示例集。对于尾字母连接任务,模型仅看到包含两个单词的名称示例,然后对包含三个和四个单词的名称执行尾字母连接操作。⁴我们对抛硬币任务中可能的抛掷次数也进行了相同的处理。我们的实验设置使用了与前两节相同的方法和模型。我们再次为每个任务的少样本示例手动构建思维链,如图 3 所示。

结果。图 8 展示了 PaLM 的领域内评估和面向对象设计 (OOD) 评估结果, LaMDA 的结果见附录表 5。对于 PaLM 540B,思维链提示几乎可以达到 100% 的求解率(值得注意的是,PaLM 540 的标准提示已经可以解决抛硬币的问题,但 LaMDA 137B 则不行)。需要注意的是,这些领域内评估是“玩具任务”,因为在样本量较小的示例中,思维链已经提供了完美的解决方案结构;模型只需在测试时示例中使用新符号重复相同的步骤即可。然而,即使是小型模型仍然会失败。只有当模型参数达到 100B 级时,才能对这三个任务中未见过的符号进行抽象操作。

至于 OOD 评估,标准提示在两项任务中均告失败。采用思维链提示后,语言模型能够实现向上扩展的曲线(尽管性能低于领域内设置)。因此,对于规模足够大的语言模型,思维链提示有助于其超越已见思维链的长度泛化。

6 讨论

我们探索了思维链提示作为一种简单的机制,用于在大型语言模型中引出多步骤推理行为。我们首先发现,思维链提示在算术推理方面显著提升了性能,其提升效果远强于消融法,并且对不同的标注者、范例和语言模型都具有鲁棒性(第 3 节)。接下来,

³我们使用 GPT-3 davinci 测试了 10 个常用名称,结果除了一个以外全部都正确。

⁴对于长度超过两个单词的姓名,我们将多个名字和姓氏连接在一起。

常识推理实验强调了思维链推理的语言特性使其具有普遍适用性（第4节）。最后，我们证明，对于符号推理，思维链提示有助于将 OOD 泛化到更长的序列长度（第5节）。在所有实验中，思维链推理仅通过提示一个现成的语言模型来诱发。在撰写本文的过程中，我们没有对任何语言模型进行微调。

随着模型规模的扩大，链式推理的出现已成为一个普遍关注的主题（Wei et al., 2022b）。对于许多标准提示能力曲线平缓的推理任务而言，链式提示却能显著提升其能力曲线。链式提示似乎扩展了大型语言模型能够成功执行的任务范围。换句话说，我们的工作强调了标准提示仅仅给出了大型语言模型能力的下限。这一观察结果可能引发的问题比解答的问题更多。例如，随着模型规模的进一步扩大，我们还能预期推理能力提升多少？

还有哪些提示方法可以扩展语言模型能够解决的任务范围？

关于局限性，首先需要指出的是，尽管思维链模拟了人类推理者的思维过程，但这并不能回答神经网络是否真的在进行“推理”，我们将其作为一个开放性问题。其次，虽然在少样本场景下手动添加思维链样本的成本很低，但这种标注成本对于微调来说可能过于高昂（尽管可以通过合成数据生成或零样本泛化来克服这一问题）。第三，推理路径的正确性无法保证，因为推理路径可能产生正确也可能产生错误的结果；改进语言模型的事实生成是未来研究的一个开放方向（Rashkin et al., 2021; Ye and Durrett, 2022; Wiegrefe et al., 2022等）。最后，思维链推理仅在大规模模型中出现，这使得它在实际应用中的成本很高；未来的研究可以探索如何在较小的模型中诱导推理。

7 相关工作

这项工作受到了许多研究领域的启发，我们在扩展的相关工作部分（附录C）中详细阐述了这些领域。在此，我们重点介绍两个可能最为相关的研究方向和相关论文。

第一个相关方向是利用中间步骤解决推理问题。Ling等人（2017）率先提出利用自然语言推理，通过一系列中间步骤来解决数学应用题。他们的工作与使用形式语言进行推理的文献（Roy等人，2015；Chiang和Chen，2019；Amini等人，2019；Chen等人，2019）形成了鲜明对比。Cobbe等人（2021）扩展了Ling等人（2017）的研究，他们创建了一个更大的数据集，并用它来微调预训练的语言模型，而不是从头开始训练模型。在程序合成领域，Nye等人（2021）利用语言模型，通过逐行预测中间计算结果来预测Python程序的最终输出，并证明他们的逐步预测方法比直接预测最终输出的效果更好。

当然，本文也与近期大量关于提示的研究密切相关。自Brown等人（2020）推广少样本提示以来，一些通用方法提升了模型的提示能力，例如自动学习提示（Lester等人，2021）或向模型提供描述任务的指令（Wei等人，2022a；Sanh等人，2022；Ouyang等人，2022）。这些方法改进或增强了提示的输入部分（例如，在输入前添加指令），而我们的工作则反其道而行之，通过构建思维链来增强语言模型的输出。

8 结论

我们探索了思维链提示作为一种简单且应用广泛的方法来增强语言模型的推理能力。通过对算术、符号和常识推理的实验，我们发现思维链推理是模型规模涌现的一种特性，它使得足够大的语言模型能够执行原本规模曲线平缓的推理任务。

扩大语言模型能够执行的推理任务范围，有望激发人们对基于语言的推理方法进行更深入的研究。

致谢

我们感谢 Jacob Devlin、Claire Cui、Andrew Dai 和 Ellie Pavlick 对本文提出的宝贵意见。我们感谢 Jacob Austin、Yuhuai Wu、Henryk Michalewski、Aitor Lewkowycz、Charles Sutton 和 Aakanksha Chowdhery 的有益讨论。我们感谢 Sid Maxwell 指出原稿中人工错误分析方面的错误。

参考

Michael Ahn、Anthony Brohan、Noah Brown、Yevgen Chebotar、Omar Cortes、Byron David、Chelsea Finn、Keerthana Gopalakrishnan、Karol Hausman、Alex Herzog 等人, 2022 年。《[尽我所能,而非我所愿](#)》。例如:将语言建立在机器人功能之上。arXiv 预印本 arXiv:2204.01691。

Aida Amini、Saadia Gabriel、Shanchuan Lin、Rik Koncel-Kedziorski、Yejin Choi 和 Hannaneh Hajishirzi。2019。MathQA [利用基于运算的形式解决可解释的数学应用问题](#)。2019 年北美计算语言学协会会议论文集:人类语言技术,第 1 卷(长篇和短篇论文),明尼苏达州明尼阿波利斯。计算语言学协会。

Daniel Andor、Luheng He、Kenton Lee 和 Emily Pitler。2019 年。《[给 BERT 一个计算器:寻找通过阅读理解进行运算和论证](#)》。EMNLP。

Jacob Andreas、Dan Klein 和 Sergey Levine。2018 年。[利用潜在语言进行学习](#)。北美动物保护协会。

Jacob Austin、Augustus Odena、Maxwell Nye、Maarten Bosma、Henryk Michalewski、David Dohan、Ellen Jiang、Carrie Cai、Michael Terry、Quoc Le 等。2021。[大语言程序综合模型](#)。arXiv 预印本 arXiv:2108.07732。

BIG-bench 合作。2021。[超越模仿游戏:衡量和推断语言模型的功能](#)。准备中。

Kaj Bostrom、赵新宇、Swarat Chaudhuri 和 Greg Durrett。2021。[灵活的自然发电语言推断](#)。EMNLP。

Tom Brown、Benjamin Mann、Nick Ryder、Melanie Subbiah、Jared D Kaplan、Prafulla Dhariwal、Arvind Neelakantan、Pranav Shyam、Girish Sastry、Amanda Askell、Sandhini Agarwal、Ariel Herbert-Voss、Gretchen Krueger、Tom Henighan、Rewon Child、Aditya Ramesh、Daniel Ziegler、Jeffrey Wu、Clemens Winter、Chris Hesse、Mark Chen、Eric Sigler、Mateusz Litwin、Scott Gray、Benjamin Chess、Jack Clark、Christopher Berner、Sam McCandlish、Alec Radford、Ilya Sutskever 和 Dario Amodei。2020 年。[语言模型是少样本学习器](#)。神经免疫学。

Jonathon Cai、Richard Shin 和 Dawn Song。2017。[构建神经编程架构利用递归进行概括](#)。ICLR。

瓦纳·玛丽亚·坎布鲁、蒂姆·洛克塔舍尔、托马斯·卢卡谢维奇和菲尔·布伦瑟姆。2018。e-SNLI:[使用自然语言进行推理并给出自然语言解释](#)。神经免疫学。

Howard Chen、Jacqueline He、Karthik Narasimhan 和 Danqi Chen。2022。[可行合理化提高鲁棒性?](#)北美动物保护协会。

Mark Chen、Jerry Tworek、Heewoo Jun、Qiming Yuan、Henrique Ponde de Oliveira Pinto、Jared Kaplan、Harri Edwards、Yuri Burda、Nicholas Joseph、Greg Brockman 等。2021。[评估基于代码训练的大型语言模型](#)。arXiv 预印本 arXiv:2107.03374。

Xinyun Chen、Chen Liang、Adams Wei Yu、Denny Zhou、Dawn Song 和 Quoc V. Le。2019。[神经符号读取器:可扩展地集成分布式和符号表示以进行读取理解](#)。ICLR。

蒋廷瑞和陈云能。2019。[用于求解的语义对齐方程生成以及推理数学应用题](#)。在 2019 年北美计算语言学协会会议论文集:人类语言技术,第 1 卷(长篇和短篇论文),第 2656-2668 页,明尼苏达州明尼阿波利斯。计算语言学协会。

Peter Clark, Oyvind Tafjord 和 Kyle Richardson. 2020 年。《变形金刚作为软推理者》[language](#). IJCAI.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Jacob Hilton, Reiichiro Nakano, Christopher Hesse 和 John Schulman. 2021 年。训练验证者解决数学应用题。arXiv 预印本 arXiv:2110.14168。

Jacob Devlin, Ming-Wei Chang, Kenton Lee 和 Kristina Toutanova. 2019 年。BERT : 预训练用于语言理解的深度双向 Transformer。北美动物保护协会。

Honghua Dong, Jiayuan Mao, Tian Lin, Chong Wang, Lihong Li, and Denny Zhou. 2019. [Neural logic machines](#). ICLR.

迪鲁·杜阿、萨米尔·辛格和卡特·加德纳。2020。阅读中级注释的好处理解。前交叉韧带。

莫尔·杰瓦、丹尼尔·卡沙比、埃拉德·西格尔、图沙尔·科特、丹·罗斯和乔纳森·贝兰特。2021。做了亚里士多德会用笔记本电脑吗？一项运用隐性推理策略的问答基准测试。TACL。

顾玉玲、巴瓦纳·达尔维·米什拉和彼得·克拉克。2022。梦想：揭示心理模型语言模型背后的原因。北美动物保护协会。

Braden Hancock, Paroma Varma, Stephanie Wang, Martin Bringmann, Percy Liang 和 Christopher Ré. 2018 年。使用自然语言解释训练分类器。前交叉韧带。

Peter Hase 和 Mohit Bansal. 2022。模型何时能从解释中学习？一个形式化框架理解解释数据的作用。前交叉韧带。

Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song 和 Jacob Steinhardt. 2021 年。使用 math 数据集衡量数学问题解决能力。arXiv 预印本 arXiv:2103.03874。

穆罕默德·贾瓦德·胡赛尼、汉纳内·哈吉什尔兹、奥伦·埃齐奥尼和内特·库什曼。2014。学习运用动词分类解决算术应用题。EMNLP。

杰占明, 李杰瑞, 卢伟. 2022。学习演绎推理：数学应用题将问题解决为复杂关系抽取。arXiv 预印本 arXiv:2203.10316。

Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu 和 Dario Amodei. 2020 年。《神经语言的标度律》模型。arXiv 预印本 arXiv:2001.08361。

Rik Koncel-Kedziorski, Subhro Roy, Aida Amini, Nate Kushman 和 Hannaneh Hajishirzi. 2016 年。MAWPS: 一个数学应用题库。北美动物保护协会。

Andrew K. Lampinen, Ishita Dasgupta, Stephanie CY Chan, Kory Matthewson, Michael Henry Tessler, Antonia Creswell, James L. McClelland, Jane X. Wang 和 Felix Hill. 2022 年。《Can 语言》模型能否从上下文解释中学习？arXiv 预印本 arXiv:2204.02329。

兰一怀、王雷、张启元、兰云石、戴秉天、王岩、张东翔和林 Ee-Peng. 2021. MWPToolkit: 基于深度学习的数学开源框架应用题解答器。arXiv 预印本 arXiv:2109.00799。

Teven Le Scao 和 Alexander Rush. 2021。一个提示信息值多少个数据点？北美动物保护协会。

Brian Lester, Rami Al-Rfou 和 Noah Constant. 2021。规模对参数效率的影响提示调谐。EMNLP。

Iddo Lev, Bill MacCartney, Christopher Manning 和 Roger Levy. 2004 年。《解决逻辑谜题》：从强大的处理能力到精确的语义表达。第二届文本意义与解释研讨会论文集。

Xiang Lisa Li 和 Percy Liang. 2021。前缀调整：优化连续提示的生成。前交叉韧带。

梁正忠、史蒂文·贝瑟德和米哈伊·苏尔德亚努。2021年。[可解释的多跳语言通过内心独白进行推理](#)。北美动物保护协会。

王玲、丹尼·尤加塔玛、克里斯·戴尔和菲尔·布伦索姆。2017年。《[按理由进行项目介绍](#)》
[一代:学习解决和解释代数应用题](#)。前交叉韧带。

Pengfei Liu, Weizhe Yuan, Jinlan Fu, Zhengbao Jiang, Hiroaki Hayashi, and Graham Neubig. 2021.
[预训练、提示和预测:自然语言提示方法的系统性综述加工](#)。arXiv 预印本 arXiv:2107.13586。

菩萨·普拉萨德·马宗德尔、瓦娜·玛丽亚·坎布鲁、托马斯·卢卡谢维奇和朱利安·麦考利。
2021。[受理性启发的常识性自然语言解释](#)。arXiv 预印本 arXiv:2106.13876。

Ana Marasovic, Iz Beltagy, Doug Downey 和 Matthew E Peters。2022年。[少发性自我合理化使用自然语言提示](#)。NAACL 研究结果。

Joshua Maynez, Shashi Narayan, Bernd Bohnet 和 Ryan McDonald。2020年。《[论忠诚与抽象概括中的事实性](#)》。在 ACL 中。

沉云淼、赵春良、克亦苏。2020。[用于评估和评估的多样化语料库](#)
[培养英语数学应用题解题能力](#)。前交叉韧带。

Sewon Min, Xinxin Lyu, Ari Holtzman, Mikel Artetxe, Mike Lewis, Hannaneh Hajishirzi 和 Luke Zettlemoyer。2022年。
《[重新思考演示的作用:是什么让情境学习奏效?](#)》arXiv 预印本 arXiv:2202.12837。

沙兰·纳朗、科林·拉斐尔、凯瑟琳·李、亚当·罗伯茨、诺亚·菲德尔和卡里什玛·马尔坎。
2020。[WT5? 训练文本到文本模型来解释其预测结果](#)。arXiv 预印本 arXiv:2004.14546。

Maxwell Nye, Anders Johan Andreassen, Guy Gur-Ari, Henryk Michalewski, Jacob Austin, David Bieber, David Dohan, Aitor Lewkowycz, Maarten Bosma, David Luan 等。2021年。[展示您的作品:使用语言模型进行中间计算的便笺本](#)。arXiv 预印本 arXiv:2112.00114。

Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray 等人, 2022年。[训练语言模型到根据指示进行操作,并接受人工反馈](#)。arXiv 预印本 arXiv:2203.02155。

Arkil Patel, Satwik Bhattamishra 和 Navin Goyal, 2021年。《[自然语言处理模型真的能够解决……](#)》
[简单的数学应用题?](#)北美动物保护协会。

马修·E·彼得斯、马克·诺伊曼、莫希特·艾耶尔、马特·加德纳、克里斯托弗·克拉克、肯顿·李和
Luke Zettlemoyer。2018。[深度语境化词表示](#)。北美动物保护协会。

Xinyu Pi, Qian Liu, Bei Chen, Morteza Ziyadi, Zeqi Lin, Yan Gao, Qiang Fu, Jian-Guang Lou, and Weizhu Chen. 2022.
[Reasoning like program executors](#). arXiv preprint arXiv:2201.11473.

彼得·皮科斯、马特乌斯·马林诺夫斯基和亨利克·米查莱夫斯基。2021。[衡量和改进](#)
[BERT 通过预测推理顺序来展现其数学能力](#)。前交叉韧带。

Jack W. Rae, Sebastian Borgeaud, Trevor Cai, Katie Millican, Jordan Hoffmann, Francis Song, John Aslanides, Sarah Henderson, Roman Ring, Susannah Young 等。2021年。[扩展语言模型: Gopher训练方法、分析和见解](#)。arXiv 预印本 arXiv:2112.11446。

Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li 和 Peter J Liu. 2020。[利用统一方法探索迁移学习的极限文本转文本转换器](#)。机器学习研究杂志, 21:1-67。

Dheeraj Rajagopal, Vidhisha Balachandran, Eduard H. Hovy 和 Yulia Tsvetkov. 2021。[自我解释:一种用于神经文本分类器的自解释架构](#)。EMNLP。

Nazneen Fatema Rajani, Bryan McCann, Caiming Xiong 和 Richard Socher. 2019。[解释一下](#)
[你自己:利用语言模型进行常识推理](#)。前交叉韧带。

- Qiu Ran, Yankai Lin, Peng Li, Jie Zhou, and Zhiyuan Liu. 2019. [NumNet: Machine reading 运用数字推理进行理解](#). EMNLP。
- Hannah Rashkin,Vitaly Nikolaev,Matthew Lamm,Michael Collins,Dipanjan Das,Slav Petrov、Gaurav Singh Tomar、Iulia Turc 和 David Reitter.2021 年。《[自然语言归因测量](#)》世代模型。arXiv 预印本 arXiv:2112.12870。
- Gabriel Recchia. 2021.[通过示范教授自回归语言模型复杂任务](#)。arXiv 预印本 arXiv:2109.02102。
- Emily Reif,Daphne Ippolito,Ann Yuan,Andy Coenen,Chris Callison-Burch 和 Jason Wei.2022 年。[利用大型语言模型实现任意文本风格迁移的方法](#)。前交叉韧带。
- Laria Reynolds 和 Kyle McDonell. 2021.[大型语言模型的提示编程:超越少镜头范式](#)。2021 年人机交互系统 CHI 会议扩展摘要。
- Subhro Roy 和 Dan Roth. 2015.[解决一般算术应用题](#)。EMNLP。
- Subhro Roy,Tim Vieira 和 Dan Roth.2015 年。[自然语言中的数量推理](#)。处理。
- 穆罕默德·赛义德·纳赛尔·艾哈迈迪、普雷斯拉夫·纳科夫和保罗·帕波蒂。2021.[RuleBERT :教学向预训练语言模型添加软规则](#)。EMNLP。
- Victor Sanh,Albert Webson,Colin Raffel,Stephen H. Bach,Lintang Sutawika,Zaid Alyafeai,Antoine Chaffin,Arnaud Stiegler,Teven Le Scao,Arun Raja 等。2022.[多任务提示训练能够实现零样本任务泛化](#)。ICLR。
- Jianhao Shen, Yichun Yin, Lin Li, Lifeng Shang, Xin Jiang, Ming Zhang, and Qun Liu. 2021. [生成和排序:一个用于解决数学应用题的多任务框架](#)。计算语言学协会的研究成果:EMNLP 2021。
- 阿隆·塔尔莫、乔纳森·赫齐格、尼古拉斯·劳里和乔纳森·贝兰特。2019.[CommonsenseQA :A 针对常识知识的问答挑战](#)。北美动物保护协会。
- Alon Talmor,Oyvind Tafjord,Peter Clark,Yoav Goldberg 和 Jonathan Berant.2020 年。[思维飞跃:教预训练模型系统地推理隐性知识](#)。神经免疫学。
- Alon Talmor,Ori Yoran,Ronan Le Bras,Chandra Bhagavatula,Yoav Goldberg,Yejin Choi 和 Jonathan Berant.2021 年。[CommonsenseQA 2.0 :通过游戏化揭示人工智能的局限性](#)。NeurIPS 数据集和基准测试专题。
- Yi Tay,Mostafa Dehghani,Vinh Q Tran,Xavier Garcia,Dara Bahri,Tal Schuster,Huaixiu Steven Zheng,Neil Houlsby 和 Donald Metzler.2022 年。[统一语言学习范式](#)。arXiv预印本 arXiv:2205.05131。
- Romal Thoppilan,Daniel De Freitas,Jamie Hall,Noam Shazeer,Apoorv Kulshreshtha,Heng-Tze Cheng,Alicia Jin、Taylor Bos,Leslie Baker,Yu Du 等。2022.LaMDA :[语言模型对话应用程序](#)。arXiv 预印本 arXiv:2201.08239。
- Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, and Denny Zhou. 2022a. [自洽性可以提高语言模型中的逻辑推理能力](#)。arXiv 预印本 arXiv:2203.11171。
- 王一中,Swaroop Mishra,Pegah Alipoormolabashi,Yeganeh Kordi,Amirreza Mirzaei,Anjana Arunkumar,Arjun Ashok、Arut Selvan Dhanasekaran,Atharva Naik,David Stap 等。2022b。[通过上下文指令对 1600 多个语言任务进行泛化基准测试](#)。arXiv 预印本 arXiv:2204.07705。
- Jason Wei,Maarten Bosma,Vincent Y. Zhao,Kelvin Guu,Adams Wei Yu,Brian Lester,Nan Du、Andrew M. Dai 和 Quoc V. Le. 2022a.[微调的语言模型是零样本学习者](#)。ICLR。

Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barrett Zoph, Sebastian Borgeaud, Dani Yogatama, Martin Bosma, Denny Zhou, Donald Metzler 等。2022b. [大语言的新兴能力模型](#)。机器学习研究论文集。

莎拉·维格瑞夫、杰克·海塞尔、斯瓦巴·斯瓦亚姆迪普塔、马克·里德尔和 Yejin Choi。2022. [重构人机协作生成自由文本解释](#)。北美动物保护协会。

Sarah Wiegrefe 和 Ana Marasovic。2021 年。 [教我如何解释:可解释数据集综述自然语言处理](#)。神经免疫学。

Sarah Wiegrefe, Ana Marasovic 和 Noah A. Smith。2021 年。 [衡量标签之间的关联性以及自由文本形式的解释](#)。EMNLP。

Tongshuang Wu, Ellen Jiang, Aaron Donsbach, Jeff Gray, Alejandra Molina, Michael Terry 和 Carrie J Cai。2022a. [PromptChainer:通过可视化链接大型语言模型提示编程](#)。CHI扩展摘要。

吴同双、Michael Terry 和 Carrie Jun Cai。2022b. [AI 链:透明且可控通过串联大型语言模型提示进行人机交互](#)。芝加哥。

Yujun Yan, Kevin Swersky, Danai Koutra, Parthasarathy Ranganathan 和 Milad Hashemi。2020. [神经执行引擎:学习执行子程序](#)。神经免疫学。

Huihan Yao, Ying Chen, Qinyuan Ye, Xisen Jin, and Xiang Ren。2021. [Refining language models with compositional explanations](#)。NeurIPS。

Xi Ye 和 Greg Durrett。2022. [小样本情境学习中解释的不可靠性](#)。arXiv 预印本 arXiv:2205.03401。

Jordan Yordanov, Vid Kocijan, Thomas Lukasiewicz 和 Oana-Maria Cambridge。2021 年。 [《少镜头摄影》](#)。自然语言解释的域外迁移学习。arXiv 预印本 arXiv:2112.06204。

Omar Zaidan, Jason Eisner 和 Christine Piatko。2007 年。 [“使用‘标注者理由’来改进”基于机器学习的文本分类](#)。北美动物保护协会。

Wojciech Zaremba 和 Ilya Sutskever。2014. [学习执行](#)。arXiv 预印本 arXiv:1410.4615。

Eric Zelikman, Yuhuai Wu 和 Noah D. Goodman。2022. [STaR:使用引导推理推理](#)。arXiv 预印本 arXiv:2203.14465。

Tony Z. Zhao, Eric Wallace, Shi Feng, Dan Klein 和 Sameer Singh。2021 年. [使用前请校准:提高语言模型的小样本性能](#)。ICML。

Wangchunshu Zhou, Jinyi Hu, Hanlin Zhang, Xiaodan Liang, Maosong Sun, Chenyan Xiong, and Jian Tang。2020. [Towards interpretable natural language understanding with explanations as latent variables](#)。NeurIPS。